

UNIVERSIDAD DEL NORTE

PROYECTO FINAL

---

# Análisis de Biomarcadores EEG para el Diagnóstico de Depresión: Un Enfoque Predictivo Basado en Deep Learning

---

*Autores:*

Adriam ARISTIZABAL  
Nicolas RODRIGUEZ  
Daniel MERIÑO

*Supervisora:*

Dra. Karen Flórez

*proyecto final para la asignatura  
seminario investigativo*

*En el*

Departamento de Matemáticas y Estadística

Noviembre 2025

*“El diagnóstico correcto es la llave de todo éxito en el tratamiento; sin esta capacidad el médico nunca será completo.”*

L. Duhring.

UNIVERSIDAD DEL NORTE

## *Resumen*

División de Ciencias Básicas  
Departamento de Matemáticas y Estadística

Pregrado en Ciencia de Datos

### **Análisis de Biomarcadores EEG para el Diagnóstico de Depresión: Un Enfoque Predictivo Basado en Deep Learning**

by Adriam ARISTIZABAL  
Nicolas RODRIGUEZ  
Daniel MERIÑO

El Trastorno Depresivo Mayor (TDM) representa uno de los desafíos más significativos para la salud pública mundial, afectando a más de 280 millones de personas. El diagnóstico actual se basa principalmente en entrevistas clínicas y cuestionarios autorreportados, métodos que dependen de la percepción subjetiva y pueden introducir variabilidad diagnóstica significativa.

Este trabajo explora el desarrollo de un sistema de diagnóstico objetivo basado en biomarcadores neurofisiológicos obtenidos mediante electroencefalografía (EEG). Utilizando el dataset multimodal MODMA (Multimodal Open Dataset for Mental-disorder Analysis), que incluye 12,024 trials de 53 participantes (MDD y controles sanos), se implementó un proceso completo de ETL para integrar señales EEG con variables clínicas como PHQ-9, GAD-7, CTQ-SF, LES, SSRS y PSQI.

El análisis exploratorio reveló diferencias significativas en los potenciales evocados relacionados con eventos (ERP) entre ambos grupos, especialmente en tareas de procesamiento emocional con estímulos de felicidad, tristeza y miedo. Los mapas topográficos mostraron patrones distintivos de activación cortical, con mayor actividad frontal en pacientes con TDM y predominancia occipital en controles sanos.

El objetivo principal es entrenar modelos predictivos basados en deep learning que permitan clasificar automáticamente pacientes con TDM utilizando únicamente señales EEG, reduciendo la dependencia de múltiples cuestionarios clínicos y facilitando un diagnóstico más rápido, objetivo y accesible.

**Palabras clave:** Electroencefalografía (EEG), Trastorno Depresivo Mayor, Deep Learning, Biomarcadores, Potenciales Evocados (ERP), Machine Learning, Diagnóstico Objetivo, Neurociencia Computacional.

## *Acknowledgements*

A la profe karen por su guía, conocimiento y sobre todo paciencia durante todo el proceso de desarrollo de este proyecto.

A los investigadores que desarrollaron y compartieron públicamente el dataset MODMA, cuya contribución a la ciencia abierta hace posible avances significativos en el campo de la salud mental.

A todos los participantes del estudio original cuya colaboración voluntaria contribuye al avance de la neurociencia y la salud mental.

# Índice general

|                                                                |            |
|----------------------------------------------------------------|------------|
| <b>Resumen</b>                                                 | <b>iii</b> |
| <b>Acknowledgements</b>                                        | <b>iv</b>  |
| <b>1 Introducción</b>                                          | <b>1</b>   |
| 1.1 Contextualización . . . . .                                | 1          |
| 1.2 Motivación . . . . .                                       | 1          |
| 1.3 Justificación . . . . .                                    | 2          |
| 1.3.1 Urgencia clínica . . . . .                               | 2          |
| 1.3.2 Impacto en productividad . . . . .                       | 2          |
| 1.3.3 Innovación metodológica . . . . .                        | 2          |
| 1.4 Alcance del proyecto . . . . .                             | 2          |
| 1.5 Organización del documento . . . . .                       | 2          |
| <b>2 Objetivos del Proyecto</b>                                | <b>4</b>   |
| 2.1 Objetivo General . . . . .                                 | 4          |
| 2.2 Objetivos Específicos . . . . .                            | 4          |
| 2.2.1 Objetivo 1: Integración de datos . . . . .               | 4          |
| 2.2.2 Objetivo 2: Análisis exploratorio . . . . .              | 4          |
| 2.2.3 Objetivo 3: Desarrollo de modelos predictivos . . . . .  | 4          |
| 2.2.4 Objetivo 4: Interpretabilidad . . . . .                  | 5          |
| 2.2.5 Objetivo 5: Optimización diagnóstica . . . . .           | 5          |
| 2.3 Impacto esperado . . . . .                                 | 5          |
| 2.4 Delimitación del alcance . . . . .                         | 6          |
| <b>3 Sobre los Datos</b>                                       | <b>7</b>   |
| 3.1 Dataset MODMA . . . . .                                    | 7          |
| 3.2 Datos de EEG . . . . .                                     | 7          |
| 3.2.1 Características técnicas . . . . .                       | 7          |
| 3.2.2 Paradigma experimental . . . . .                         | 7          |
| 3.2.3 Ventana temporal . . . . .                               | 8          |
| 3.3 Variables clínicas y sociodemográficas . . . . .           | 8          |
| 3.3.1 Cuestionarios clínicos . . . . .                         | 8          |
| PHQ-9 (Patient Health Questionnaire-9) . . . . .               | 8          |
| GAD-7 (Generalized Anxiety Disorder-7) . . . . .               | 9          |
| CTQ-SF (Childhood Trauma Questionnaire – Short Form) . . . . . | 9          |
| LES (Life Event Scale) . . . . .                               | 9          |
| SSRS (Social Support Rating Scale) . . . . .                   | 9          |
| PSQI (Pittsburgh Sleep Quality Index) . . . . .                | 9          |
| 3.3.2 Variables sociodemográficas . . . . .                    | 9          |
| 3.4 Estructura de la muestra . . . . .                         | 10         |
| 3.4.1 Tamaño muestral . . . . .                                | 10         |
| 3.4.2 Distribución por género . . . . .                        | 10         |

|          |                                                             |           |
|----------|-------------------------------------------------------------|-----------|
| 3.5      | Decisiones metodológicas                                    | 10        |
| 3.5.1    | Trials como unidad de análisis                              | 10        |
| 3.5.2    | Integración multimodal                                      | 11        |
| <b>4</b> | <b>ETL: Extracción, Transformación y Carga de los datos</b> | <b>12</b> |
| 4.1      | Extracción                                                  | 12        |
| 4.1.1    | Datos de EEG                                                | 12        |
| 4.1.2    | Variables clínicas                                          | 12        |
| 4.2      | Transformación                                              | 13        |
| 4.2.1    | Preprocesamiento del EEG                                    | 13        |
|          | Filtrado de frecuencias                                     | 13        |
|          | Re-referenciación                                           | 13        |
| 4.2.2    | Segmentación (Epoching)                                     | 13        |
| 4.2.3    | Selección de electrodos                                     | 14        |
| 4.2.4    | Mapeo de eventos y condiciones                              | 14        |
| 4.2.5    | Rechazo de artefactos                                       | 14        |
| 4.2.6    | Construcción del dataset wide                               | 14        |
| 4.2.7    | Validación                                                  | 15        |
| 4.2.8    | Integración con variables clínicas                          | 15        |
| 4.3      | Carga                                                       | 16        |
| 4.3.1    | Ventajas del formato Parquet                                | 16        |
| 4.3.2    | Documentación de metadatos                                  | 16        |
| 4.4      | Resumen del proceso ETL                                     | 16        |
| <b>5</b> | <b>Análisis Exploratorio de Datos (EDA)</b>                 | <b>18</b> |
| 5.1      | Variables Clínicas                                          | 18        |
| 5.1.1    | Diccionario de variables                                    | 18        |
| 5.1.2    | Distribución de variables clínicas por grupo                | 18        |
| 5.1.3    | Análisis de correlación                                     | 19        |
| 5.1.4    | Implicaciones para el modelado                              | 20        |
| 5.2      | Datos de EEG                                                | 21        |
| 5.2.1    | Distribución de trials                                      | 21        |
| 5.2.2    | Distribución de amplitudes                                  | 21        |
| 5.2.3    | Potenciales evocados promedio (ERPs)                        | 22        |
| 5.2.4    | Mapas topográficos de actividad cerebral                    | 23        |
|          | Análisis de caso individual                                 | 23        |
|          | Comparación entre grupos                                    | 24        |
| 5.2.5    | Correlación intra- e inter-sujeto                           | 24        |
| 5.2.6    | Análisis por ventanas temporales                            | 25        |
| 5.3      | Síntesis del análisis exploratorio                          | 26        |
| 5.3.1    | Variables clínicas                                          | 26        |
| 5.3.2    | Señales EEG                                                 | 26        |
| 5.3.3    | Implicaciones para el modelado                              | 26        |
| <b>6</b> | <b>Marco Teórico y Revisión de Literatura</b>               | <b>28</b> |
| 6.1      | Neurobiología de la Depresión Mayor                         | 28        |
| 6.1.1    | Epidemiología y relevancia clínica                          | 28        |
| 6.1.2    | Bases neurobiológicas                                       | 28        |
|          | Circuitos neuronales afectados                              | 28        |
|          | Sistemas de neurotransmisores                               | 29        |
| 6.1.3    | Modelos teóricos                                            | 29        |

|          |                                                                  |           |
|----------|------------------------------------------------------------------|-----------|
|          | Modelo de sesgo atencional negativo . . . . .                    | 29        |
| 6.2      | Electroencefalografía (EEG) . . . . .                            | 29        |
| 6.2.1    | Fundamentos fisiológicos . . . . .                               | 29        |
| 6.2.2    | Bandas de frecuencia . . . . .                                   | 30        |
| 6.2.3    | Potenciales Evocados Relacionados con Eventos (ERP) . . . . .    | 30        |
|          | Componentes ERP relevantes para depresión . . . . .              | 30        |
| 6.2.4    | EEG en el estudio de la depresión . . . . .                      | 31        |
| 6.3      | Machine Learning en Neuropsiquiatría . . . . .                   | 31        |
| 6.3.1    | Motivación para enfoques de ML/DL . . . . .                      | 31        |
| 6.3.2    | Estado del arte . . . . .                                        | 31        |
|          | Métodos tradicionales de ML . . . . .                            | 31        |
|          | Enfoques de Deep Learning . . . . .                              | 32        |
| 6.3.3    | Desafíos y consideraciones . . . . .                             | 32        |
|          | Tamaño de muestra . . . . .                                      | 32        |
|          | Interpretabilidad . . . . .                                      | 32        |
|          | Generalización . . . . .                                         | 33        |
| 6.4      | Trabajos relacionados . . . . .                                  | 33        |
| 6.4.1    | Revisión sistemática de Simmatis et al. (2023) . . . . .         | 33        |
| 6.4.2    | Deep learning con EEG (Ay et al., 2019) . . . . .                | 33        |
| 6.4.3    | Comparación de ML tradicional vs DL (Lin et al., 2024) . . . . . | 33        |
| 6.4.4    | EDT: Modelo basado en atención (Ying et al., 2024) . . . . .     | 34        |
| 6.5      | Propuesta de este trabajo . . . . .                              | 34        |
| <b>7</b> | <b>Metodología de Modelado</b> . . . . .                         | <b>35</b> |
| 7.1      | Modelos Utilizados . . . . .                                     | 35        |
| 7.2      | Fundamentos Matemáticos . . . . .                                | 35        |
| 7.2.1    | Random Forest . . . . .                                          | 35        |
| 7.2.2    | Perceptrón Multicapa (MLP) . . . . .                             | 36        |
| 7.2.3    | Análisis de Componentes Principales (PCA) . . . . .              | 36        |
| 7.2.4    | Regularización y Optimización . . . . .                          | 36        |
| 7.3      | Estrategia de Validación . . . . .                               | 36        |
| 7.4      | Métricas de Evaluación . . . . .                                 | 36        |
| <b>8</b> | <b>Resultados y Análisis Comparativo</b> . . . . .               | <b>37</b> |
| 8.1      | Resultados Individuales . . . . .                                | 37        |
| 8.2      | Análisis Comparativo . . . . .                                   | 37        |
| 8.3      | Análisis de Errores . . . . .                                    | 38        |
| 8.4      | Posibles Mejoras . . . . .                                       | 38        |
| 8.5      | Conclusiones Parciales . . . . .                                 | 39        |
|          | <b>Bibliografía</b> . . . . .                                    | <b>40</b> |

# Índice de figuras

|     |                                                                                                                                                               |    |
|-----|---------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| 5.1 | Distribución de variables clínicas por grupo (MDD vs HC). Las líneas verticales punteadas indican las medianas de cada grupo. . . . .                         | 19 |
| 5.2 | Matriz de correlación entre variables clínicas y grupo (MDD vs HC). Los colores más intensos indican correlaciones más fuertes. . . . .                       | 20 |
| 5.3 | Número de trials por paciente y condición (Fear, Happy, Sad). Cada barra representa un participante individual. . . . .                                       | 21 |
| 5.4 | Distribución de la señal a 0.300 segundos por grupo (MDD vs HC). Las distribuciones muestran forma aproximadamente normal centrada en cero. . . . .           | 22 |
| 5.5 | Potenciales evocados promedio (ERPs) por condición (Happy, Sad, Fear) en ambos grupos (MDD y HC). Las áreas sombreadas representan el error estándar. . . . . | 22 |
| 5.6 | Mapas topográficos para un paciente con MDD bajo estímulos de tristeza (izquierda), felicidad (centro) y miedo (derecha) en la ventana 280-320 ms. . . . .    | 23 |
| 5.7 | Comparación de mapas topográficos promedio entre pacientes MDD (izquierda) y HC (derecha) bajo un estímulo de felicidad (280–320 ms, componente P2). . . . .  | 24 |
| 5.8 | Correlación intra-sujeto promedio por grupo (MDD vs HC). No se observaron diferencias significativas entre grupos ( $p = 0.7704$ ). . . . .                   | 25 |



# Índice de tablas

|                                                                     |    |
|---------------------------------------------------------------------|----|
| 3.1 Composición del dataset MODMA . . . . .                         | 10 |
| 3.2 Distribución por género . . . . .                               | 10 |
| 4.1 Mapeo de eventos a condiciones . . . . .                        | 14 |
| 4.2 Estructura del dataset wide . . . . .                           | 14 |
| 5.1 Variables clínicas del estudio . . . . .                        | 18 |
| 5.2 Diferencias MDD-HC por ventana temporal . . . . .               | 26 |
| 6.1 Bandas de frecuencia EEG y sus correlatos funcionales . . . . . | 30 |
| 6.2 Comparación de métodos (adaptado de Lin et al., 2024) . . . . . | 33 |
| 8.1 Desempeño comparativo de los modelos evaluados. . . . .         | 37 |

# List of Abbreviations

|               |                                                                            |
|---------------|----------------------------------------------------------------------------|
| <b>TDM</b>    | <b>Trastorno Depresivo Mayor</b>                                           |
| <b>MDD</b>    | <b>Major Depressive Disorder</b>                                           |
| <b>HC</b>     | <b>Healthy Controls (Controles Sanos)</b>                                  |
| <b>EEG</b>    | <b>Electroencefalografía</b>                                               |
| <b>ERP</b>    | <b>Event-Related Potentials (Potenciales Evocados)</b>                     |
| <b>MODMA</b>  | <b>Multimodal Open Dataset for Mental-disorder Analysis</b>                |
| <b>ETL</b>    | <b>Extracción, Transformación y Carga</b>                                  |
| <b>EDA</b>    | <b>Exploratory Data Analysis (Análisis Exploratorio)</b>                   |
| <b>PHQ-9</b>  | <b>Patient Health Questionnaire-9</b>                                      |
| <b>GAD-7</b>  | <b>Generalized Anxiety Disorder-7</b>                                      |
| <b>CTQ-SF</b> | <b>Childhood Trauma Questionnaire - Short Form</b>                         |
| <b>LES</b>    | <b>Life Event Scale</b>                                                    |
| <b>SSRS</b>   | <b>Social Support Rating Scale</b>                                         |
| <b>PSQI</b>   | <b>Pittsburgh Sleep Quality Index</b>                                      |
| <b>OMS</b>    | <b>Organización Mundial de la Salud</b>                                    |
| <b>DSM-5</b>  | <b>Diagnostic and Statistical Manual of Mental Disorders - 5th Edition</b> |
| <b>MRI</b>    | <b>Magnetic Resonance Imaging</b>                                          |
| <b>fMRI</b>   | <b>functional MRI</b>                                                      |
| <b>DALYs</b>  | <b>Disability-Adjusted Life Years</b>                                      |

*A todos aquellos que luchan contra la depresión.  
A nuestras familias por su apoyo incondicional.  
A la ciencia abierta y colaborativa que hace posible avances  
como este.*

## Chapter 1

# Introducción

### 1.1 Contextualización

El Trastorno Depresivo Mayor (TDM) es uno de los problemas de salud pública más urgentes a nivel mundial, reconocido como una de las principales causas de discapacidad y pérdida de productividad en adultos. Según la Organización Mundial de la Salud (World Health Organization, 2024), más de 280 millones de personas viven actualmente con depresión, y se estima que el trastorno contribuye de manera significativa a los años de vida ajustados por discapacidad (DALYs). La depresión no solo afecta la calidad de vida del individuo, sino que también impacta en la economía: la OMS ha estimado que los trastornos de ansiedad y depresión cuestan a la economía global más de 1 billón de dólares anuales en productividad perdida.

El diagnóstico clínico del Trastorno Depresivo Mayor se realiza actualmente a partir de los criterios establecidos en manuales internacionales como el DSM-5 y la CIE-11, mediante entrevistas clínicas estructuradas o semiestructuradas. Para complementar este proceso, con frecuencia se emplean cuestionarios estandarizados como el PHQ-9, GAD-7 o escalas de apoyo social, que ayudan a evaluar la severidad de síntomas y el impacto funcional. Sin embargo, tanto las entrevistas como los cuestionarios dependen de la percepción subjetiva del paciente y de la experiencia del clínico, lo que introduce variabilidad diagnóstica y puede retrasar la detección temprana.

En este contexto, la búsqueda de biomarcadores neurofisiológicos objetivos, particularmente aquellos obtenidos mediante electroencefalografía (EEG), ha cobrado relevancia en la última década como un posible complemento al diagnóstico tradicional. El EEG ofrece una alternativa no invasiva, de bajo costo y con alta resolución temporal para caracterizar procesos neuronales vinculados a la depresión.

### 1.2 Motivación

Investigaciones recientes han demostrado diferencias en la actividad eléctrica cortical entre adultos con TDM y controles sanos, especialmente en tareas de procesamiento emocional (Sadeghi et al., 2024). Estas alteraciones, observadas a través de potenciales evocados relacionados con eventos (ERP), sugieren la viabilidad de construir sistemas de diagnóstico más rápidos, accesibles y objetivos.

El presente proyecto se enmarca en esta línea, explorando la plausibilidad de entrenar modelos predictivos capaces de discriminar entre pacientes con TDM y controles sanos utilizando únicamente señales EEG. La reducción en la dependencia de múltiples cuestionarios clínicos permitiría, a largo plazo, un proceso diagnóstico más barato, menos invasivo y con mayor cobertura poblacional.

## 1.3 Justificación

La relevancia de este estudio se sustenta en tres pilares fundamentales:

### 1.3.1 Urgencia clínica

El diagnóstico temprano y preciso del TDM es un desafío prioritario para la salud pública. Los métodos actuales, basados en entrevistas y auto-reportes, no siempre capturan de manera confiable la complejidad del trastorno, lo que genera retrasos en el tratamiento y aumenta el riesgo de cronicidad. Un sistema basado en biomarcadores objetivos podría complementar la evaluación clínica tradicional y mejorar la precisión diagnóstica.

### 1.3.2 Impacto en productividad

En adultos, la depresión afecta directamente la capacidad laboral y la productividad. Estudios internacionales estiman que los trastornos depresivos contribuyen de forma sustancial al ausentismo, presentismo y pérdidas económicas anuales de miles de millones de dólares. Un sistema de diagnóstico más rápido y barato puede reducir este impacto mediante la detección temprana y la intervención oportuna.

### 1.3.3 Innovación metodológica

El presente trabajo propone un enfoque innovador al explorar si es posible construir un modelo predictivo utilizando únicamente EEG, reduciendo así la necesidad de múltiples cuestionarios clínicos. Si se logra demostrar una capacidad predictiva robusta, se abriría la posibilidad de desarrollar herramientas diagnósticas más objetivas, escalables y accesibles para la población general.

El uso de técnicas de deep learning permite capturar patrones complejos y no lineales en las señales EEG que podrían no ser evidentes mediante métodos estadísticos tradicionales. Esto representa un avance significativo en la intersección entre neurociencia computacional, inteligencia artificial y salud mental.

## 1.4 Alcance del proyecto

Este proyecto se enfoca específicamente en:

- El análisis de señales EEG durante tareas de procesamiento emocional (estímulos de felicidad, tristeza y miedo)
- La población adulta con diagnóstico de Trastorno Depresivo Mayor
- El desarrollo de modelos de clasificación binaria (MDD vs HC)
- La exploración de la interpretabilidad de los modelos para identificar biomarcadores relevantes

## 1.5 Organización del documento

El resto de este documento se organiza de la siguiente manera:

- **Capítulo 2:** Presenta los objetivos general y específicos del proyecto

- **Capítulo 3:** Describe detalladamente el dataset MODMA y las decisiones metodológicas
- **Capítulo 4:** Explica el proceso de ETL aplicado a los datos
- **Capítulo 5:** Presenta el análisis exploratorio de datos (EDA)
- **Capítulo 6:** Describe el marco teórico y la revisión de literatura
- **Capítulo 7:** Detalla el desarrollo, entrenamiento y evaluación de los modelos predictivos basados en EEG
- **Capítulo 8:** Presenta las conclusiones, limitaciones y posibles líneas de trabajo futuro

## Chapter 2

# Objetivos del Proyecto

### 2.1 Objetivo General

Desarrollar un análisis exploratorio y predictivo de señales EEG para evaluar la viabilidad de identificar biomarcadores que permitan clasificar de manera automática a adultos con Trastorno Depresivo Mayor (MDD) frente a controles sanos (HC).

### 2.2 Objetivos Específicos

#### 2.2.1 Objetivo 1: Integración de datos

Implementar un proceso de ETL (Extracción, Transformación y Carga) para integrar las señales EEG y las variables clínicas del dataset MODMA en un formato estructurado y consistente.

**Resultados esperados:**

- Dataset consolidado que integre señales EEG con variables clínicas
- Documentación completa del proceso de preprocesamiento
- Código reproducible y bien documentado

#### 2.2.2 Objetivo 2: Análisis exploratorio

Analizar y comparar mediante EDA (Exploratory Data Analysis) las características clínicas y neurofisiológicas de los grupos MDD y HC.

**Resultados esperados:**

- Caracterización estadística de las diferencias entre grupos
- Visualizaciones de potenciales evocados (ERP)
- Mapas topográficos de actividad cerebral
- Análisis de correlaciones entre variables clínicas y neurofisiológicas

#### 2.2.3 Objetivo 3: Desarrollo de modelos predictivos

Entrenar y evaluar modelos predictivos basados en aprendizaje automático y deep learning para clasificar MDD vs HC utilizando únicamente datos de EEG, evaluando su precisión y estabilidad.

**Resultados esperados:**

- Modelos de clasificación con métricas de desempeño reportadas

- Comparación entre diferentes arquitecturas de deep learning
- Validación cruzada para evaluar la estabilidad de los modelos
- Análisis de errores y casos difíciles

#### 2.2.4 Objetivo 4: Interpretabilidad

Explorar la interpretabilidad de los modelos, identificando qué componentes ERP y regiones corticales aportan mayor capacidad discriminativa.

**Resultados esperados:**

- Identificación de biomarcadores EEG más relevantes
- Mapas de importancia de características
- Análisis de ventanas temporales críticas
- Validación neurobiológica de los hallazgos

#### 2.2.5 Objetivo 5: Optimización diagnóstica

Evaluar si es posible reducir la cantidad de pruebas necesarias para el diagnóstico sin comprometer la eficacia predictiva.

**Resultados esperados:**

- Análisis de la contribución de cada cuestionario clínico
- Evaluación del desempeño usando solo EEG vs EEG + cuestionarios
- Propuesta de protocolo diagnóstico optimizado
- Análisis costo-beneficio del enfoque propuesto

### 2.3 Impacto esperado

El logro de estos objetivos contribuirá a:

1. **Avance científico:** Ampliar el conocimiento sobre biomarcadores neurofisiológicos de la depresión y la aplicabilidad de deep learning en neuropsiquiatría
2. **Innovación metodológica:** Demostrar la viabilidad de sistemas de diagnóstico basados en EEG que complementen la evaluación clínica tradicional
3. **Aplicación clínica:** Sentar las bases para el desarrollo futuro de herramientas diagnósticas más objetivas, rápidas y accesibles
4. **Salud pública:** Contribuir a la detección temprana de TDM, potencialmente reduciendo la carga de discapacidad y los costos asociados al trastorno



## 2.4 Delimitación del alcance

Es importante señalar que este proyecto:

- Se enfoca en la **clasificación binaria** (MDD vs HC), no en la predicción de severidad o subtipos de depresión
- Utiliza un dataset específico (MODMA) que, aunque valioso, tiene limitaciones en tamaño muestral
- No pretende reemplazar el diagnóstico clínico, sino complementarlo con evidencia objetiva
- Se centra en adultos, sin extenderse a población pediátrica o geriátrica
- Analiza únicamente tareas de procesamiento emocional, no estado de reposo u otros paradigmas

Los resultados de este trabajo deben considerarse como un paso exploratorio hacia sistemas de diagnóstico asistido por IA, requiriendo validación adicional en poblaciones más amplias y diversas antes de cualquier aplicación clínica.

## Chapter 3

# Sobre los Datos

### 3.1 Dataset MODMA

La base de datos utilizada corresponde al *Multimodal Open Dataset for Mental-disorder Analysis* (MODMA), un repositorio público diseñado para la investigación en neurociencia computacional y el estudio de trastornos mentales mediante técnicas de aprendizaje automático. MODMA es de carácter **multimodal**, pues incluye diferentes tipos de información: registros de electroencefalografía (EEG), resonancia magnética (MRI), resonancia funcional (fMRI), escalas clínicas y cuestionarios sociodemográficos.

Aunque el dataset ofrece múltiples modalidades, en este proyecto se emplean exclusivamente los registros de EEG y las variables clínicas y sociodemográficas asociadas, con el fin de explorar su capacidad predictiva en el diagnóstico de *Major Depressive Disorder* (MDD) frente a controles sanos (HC).

### 3.2 Datos de EEG

#### 3.2.1 Características técnicas

Los datos de EEG provienen de archivos en formato `.raw`, obtenidos mediante equipos EGI Net Station con hasta 128 electrodos por sujeto. Estas señales permiten el análisis de potenciales evocados relacionados con eventos (ERP), especialmente en condiciones emocionales.

##### Especificaciones técnicas:

- **Sistema de adquisición:** EGI Net Station
- **Número de canales:** Hasta 128 electrodos (E1–E128)
- **Frecuencia de muestreo:** 250 Hz
- **Sistema de referencia:** Vértex (Cz)
- **Impedancia:** < 50 k $\Omega$

#### 3.2.2 Paradigma experimental

Cada ensayo (*trial*) corresponde a una ventana temporal desde 200 ms antes hasta 600 ms después del estímulo, lo que facilita la identificación de componentes ERP en intervalos críticos de procesamiento emocional. Los participantes fueron expuestos a tres tipos de estímulos emocionales:

- **Happy (Felicidad):** Imágenes con contenido emocional positivo

- **Sad (Tristeza):** Imágenes con contenido emocional negativo asociado a tristeza
- **Fear (Miedo):** Imágenes con contenido emocional negativo asociado a amenaza

La elección de estos tres estados emocionales se basa en teorías del procesamiento emocional que sugieren que los pacientes con TDM presentan alteraciones específicas en el procesamiento de emociones positivas y negativas.

### 3.2.3 Ventana temporal

La ventana de análisis (-200 ms a 600 ms) fue seleccionada para capturar los principales componentes ERP asociados al procesamiento emocional:

- **Baseline (-200 a 0 ms):** Periodo previo al estímulo usado para corrección de línea base
- **P1 (80-120 ms):** Primer componente positivo, asociado a procesamiento visual temprano
- **N1 (120-200 ms):** Componente negativo asociado a atención selectiva
- **P2 (200-300 ms):** Componente positivo asociado a detección de características relevantes
- **N2 (300-400 ms):** Componente negativo asociado a procesamiento de conflicto
- **P3/LPP (400-600 ms):** Potencial positivo tardío asociado a evaluación emocional profunda

## 3.3 Variables clínicas y sociodemográficas

Además de las señales EEG, el dataset incluye un archivo en formato Excel con información clínica y demográfica de los participantes. Estas variables complementan los datos neurofisiológicos y permiten analizar correlaciones entre características personales y patrones de actividad cerebral.

### 3.3.1 Cuestionarios clínicos

#### PHQ-9 (Patient Health Questionnaire-9)

Cuestionario de 9 ítems para evaluar la presencia y severidad de síntomas depresivos en las últimas dos semanas. Cada ítem se califica de 0 a 3, con una puntuación total de 0-27.

##### Interpretación:

- 0-4: Mínima depresión
- 5-9: Depresión leve
- 10-14: Depresión moderada
- 15-19: Depresión moderadamente severa
- 20-27: Depresión severa

**GAD-7 (Generalized Anxiety Disorder-7)**

Cuestionario de 7 ítems para evaluar síntomas de ansiedad generalizada. La comorbilidad entre depresión y ansiedad es alta, haciendo relevante su evaluación conjunta.

**Interpretación:**

- 0-4: Ansiedad mínima
- 5-9: Ansiedad leve
- 10-14: Ansiedad moderada
- 15-21: Ansiedad severa

**CTQ-SF (Childhood Trauma Questionnaire – Short Form)**

Evalúa experiencias adversas en la infancia, incluyendo abuso emocional, físico, sexual, y negligencia emocional y física. El trauma infantil es un factor de riesgo bien establecido para el desarrollo de TDM en la vida adulta.

**LES (Life Event Scale)**

Recoge experiencias de eventos vitales estresantes recientes. Los eventos estresantes pueden precipitar episodios depresivos en individuos vulnerables.

**SSRS (Social Support Rating Scale)**

Mide el nivel de apoyo social percibido. El apoyo social actúa como factor protector contra la depresión y se asocia con mejor pronóstico.

**PSQI (Pittsburgh Sleep Quality Index)**

Evalúa la calidad del sueño y la presencia de problemas relacionados. Las alteraciones del sueño son un síntoma cardinal de la depresión y pueden preceder al inicio del trastorno.

**3.3.2 Variables sociodemográficas**

- **Edad:** Años cumplidos al momento de la evaluación
- **Educación:** Años de educación formal completados
- **Género:** Masculino o Femenino

## 3.4 Estructura de la muestra

### 3.4.1 Tamaño muestral

TABLE 3.1: Composición del dataset MODMA

| Categoría                | N             | Porcentaje |
|--------------------------|---------------|------------|
| Total de individuos      | 53            | 100%       |
| Total de trials          | 12,025        | 100%       |
| Grupo MDD                |               |            |
| Trials MDD               | 5,014         | 41.7%      |
| Grupo HC                 |               |            |
| Trials HC                | 7,011         | 58.3%      |
| <b>Proporción MDD:HC</b> | <b>1:1.40</b> |            |

### 3.4.2 Distribución por género

TABLE 3.2: Distribución por género

| Género           | N trials     | Porcentaje |
|------------------|--------------|------------|
| Masculino        | 8,554        | 71.1%      |
| Femenino         | 3,471        | 28.9%      |
| <b>Razón H:M</b> | <b>2.5:1</b> |            |

**Nota:** La distribución de género en esta muestra difiere de la prevalencia poblacional de TDM, donde la depresión es más frecuente en mujeres (razón aproximada 2:1). Esta característica debe considerarse al interpretar los resultados.

## 3.5 Decisiones metodológicas

### 3.5.1 Trials como unidad de análisis

Una decisión clave de este proyecto consiste en tratar cada observación (*trial*) como una instancia independiente en el análisis. Esta decisión se justifica por:

1. **Variabilidad intra-sujeto:** Cada trial representa una respuesta cerebral única ante un estímulo específico
2. **Número no uniforme:** El número de ensayos por sujeto no es uniforme
3. **Robustez estadística:** Incrementa la cantidad de datos útiles disponibles
4. **Precedente en la literatura:** Esta aproximación es común en estudios de ERP

#### Consideraciones:

- Los trials del mismo sujeto no son completamente independientes
- Se implementarán técnicas de validación cruzada que respeten la agrupación por sujeto
- Se reportarán métricas tanto a nivel de trial como a nivel de sujeto

### 3.5.2 Integración multimodal

Los datos de EEG y las variables clínicas fueron integrados en un **único dataset estructurado**, el cual constituye la base para el análisis exploratorio y el desarrollo de modelos predictivos. Esta integración permitió pasar de información cruda y heterogénea a un formato consistente y optimizado para su análisis computacional.

El proceso de integración se describe en detalle en el Capítulo 4.

## Chapter 4

# ETL: Extracción, Transformación y Carga de los datos

El proceso de ETL aplicado a los datos de EEG y clínicos se llevó a cabo en varias etapas, con el objetivo de integrar la información cruda proveniente de los archivos .raw de EGI y los registros clínicos en Excel, en un único dataset estructurado y listo para el análisis.

### 4.1 Extracción

La fase de extracción involucró la lectura de datos desde múltiples fuentes heterogéneas.

#### 4.1.1 Datos de EEG

- Se cargaron múltiples archivos .raw de EEG utilizando la librería **MNE-Python**
- Cada archivo corresponde a un participante individual
- Los archivos contienen información de hasta 128 canales EEG
- Se extrajeron las anotaciones de eventos que indican el tipo de estímulo y su momento de presentación

##### Código de ejemplo:

```
import mne

# Cargar archivo .raw
raw = mne.io.read_raw_egi('subject_01.raw', preload=True)

# Extraer información del sistema
print(f"Frecuencia de muestreo: {raw.info['sfreq']} Hz")
print(f"Número de canales: {len(raw.ch_names)}")
```

#### 4.1.2 Variables clínicas

- Se importaron las variables clínicas y sociodemográficas desde el archivo `pacientes.xlsx`
- El archivo contiene una fila por participante con todos los cuestionarios
- Se identificaron y corrigieron inconsistencias en los identificadores de sujetos

## 4.2 Transformación

La fase de transformación fue la más compleja del proceso ETL, involucrando múltiples pasos de preprocesamiento y limpieza.

### 4.2.1 Preprocesamiento del EEG

#### Filtrado de frecuencias

Se aplicaron dos tipos de filtros para limpiar las señales:

1. **Filtro notch (60/120 Hz):** Elimina el ruido de la red eléctrica y sus armónicos

```
raw.notch_filter(freqs=[60, 120])
```

2. **Filtro pasa-banda (0.5–40 Hz):** Conserva únicamente las frecuencias relevantes para el análisis de ERP

```
raw.filter(l_freq=0.5, h_freq=40.0)
```

#### Justificación:

- Frecuencias < 0.5 Hz: Contienen derivas lentas y artefactos de movimiento
- Frecuencias > 40 Hz: Principalmente ruido muscular y de alta frecuencia
- El rango 0.5-40 Hz captura las bandas relevantes: delta, theta, alpha, beta y gamma baja

#### Re-referenciación

Los electrodos fueron re-referenciados para mejorar la calidad de la señal y facilitar comparaciones entre sujetos.

```
# Re-referenciar a promedio común  
raw.set_eeg_reference('average')
```

**Justificación:** La referencia promedio es estándar en análisis de ERP y reduce artefactos específicos de un electrodo de referencia.

### 4.2.2 Segmentación (Epoching)

Los datos continuos se cortaron en intervalos (epochs) centrados en los eventos de interés.

```
# Definir ventana temporal  
tmin, tmax = -0.2, 0.6  
  
# Crear epochs  
epochs = mne.Epochs(raw, events, event_id, tmin, tmax,  
                    baseline=(None, 0), preload=True)
```



**Parámetros:**

- **tmin = -0.2 s:** 200 ms antes del estímulo (baseline)
- **tmax = 0.6 s:** 600 ms después del estímulo
- **baseline:** Corrección respecto al promedio pre-estímulo

**4.2.3 Selección de electrodos**

Se mantuvieron los 128 canales (E1–E128) para preservar la información espacial completa. Aunque esto aumenta la dimensionalidad, permite análisis topográficos detallados y posterior selección de características.

**4.2.4 Mapeo de eventos y condiciones**

Las anotaciones de los archivos .raw fueron estandarizadas y agrupadas en tres condiciones emocionales:

TABLE 4.1: Mapeo de eventos a condiciones

| Evento en archivo    | Condición |
|----------------------|-----------|
| 'HAPP', 'happy', 'H' | Happy     |
| 'FEAR', 'fear', 'F'  | Fear      |
| 'SAD', 'sad', 'S'    | Sad       |

**4.2.5 Rechazo de artefactos**

Se implementó un procedimiento automático para eliminar epochs contaminadas con artefactos:

```
# Rechazar epochs con amplitud > 100 µV
epochs.drop_bad(reject={'eeg': 100e-6})
```

**Criterios de rechazo:**

- Amplitud pico-a-pico > 100 µV: Indica artefactos de movimiento o parpadeo
- Se registró el número de epochs rechazadas por sujeto para control de calidad

**4.2.6 Construcción del dataset wide**

Cada ensayo (trial) se organizó como una fila en un formato tabular con la siguiente estructura:

TABLE 4.2: Estructura del dataset wide

| Columnas                | Descripción                                    |
|-------------------------|------------------------------------------------|
| Subject                 | Identificador único del participante           |
| Group                   | MDD o HC                                       |
| Condition               | Happy, Fear o Sad                              |
| Trial                   | Número de trial                                |
| E1_t001, ..., E128_t200 | Amplitud (µV) de cada electrodo en cada tiempo |

**Dimensionalidad:**

- Número de tiempos: 200 (desde -0.2 a 0.6 s con paso de 0.004 s)
- Número de electrodos: 128
- Características por trial:  $128 \times 200 = 25,600$
- Total de filas (trials): 12,025

#### 4.2.7 Validación

Se implementaron múltiples verificaciones de calidad:

1. **Consistencia de nodos:** Verificar que todos los trials tengan los mismos 128 electrodos

```
assert df.filter(regex='E\d+').shape[1] == 128 * 200
```

2. **Regularidad temporal:** Confirmar paso constante de 0.004 s (250 Hz)

```
times = np.arange(-0.2, 0.6, 0.004)
assert len(times) == 200
```

3. **Valores válidos:** Verificar ausencia de NaN o infinitos

```
assert not df.isnull().any().any()
assert np.isfinite(df.select_dtypes(float)).all().all()
```

#### 4.2.8 Integración con variables clínicas

Se limpiaron y normalizaron las columnas del archivo `pacientes.xlsx`:

1. **Limpieza de identificadores:**

- Eliminar espacios en blanco
- Estandarizar formato (ej: 'MDD\_001' vs 'MDD001')
- Crear identificador canónico único

2. **Codificación de variables categóricas:**

```
df['Gender'] = df['Gender'].map({'M': 0, 'F': 1})
df['Group'] = df['Group'].map({'HC': 0, 'MDD': 1})
```

3. **Manejo de valores faltantes:**

- Documentar patrones de missingness
- Decidir estrategia: imputación vs eliminación
- Para este estudio: casos completos solamente

4. **Join de datasets:**

```
df_final = df_eeg.merge(df_clinical, on='Subject', how='left')
```

## 4.3 Carga

El dataset final fue exportado en formato Parquet, lo cual permite un manejo más eficiente de memoria y velocidad de acceso.

### 4.3.1 Ventajas del formato Parquet

- **Compresión eficiente:** Reduce el tamaño del archivo significativamente vs CSV
- **Tipado fuerte:** Preserva tipos de datos (int, float, string)
- **Lectura columnar:** Permite cargar solo las columnas necesarias
- **Compatible con big data:** Funciona con Spark, Dask, pandas

```
# Guardar dataset
df_final.to_parquet('modma_integrated.parquet',
                    compression='snappy',
                    index=False)

# Tamaño resultante
print(f"Tamaño CSV: {csv_size / 1e9:.2f} GB")
print(f"Tamaño Parquet: {parquet_size / 1e9:.2f} GB")
print(f"Compresión: {csv_size / parquet_size:.1f}x")
```

### 4.3.2 Documentación de metadatos

Se creó un archivo complementario de metadatos:

```
metadata = {
    'n_subjects': 53,
    'n_trials': 12025,
    'n_electrodes': 128,
    'sampling_rate': 250,
    'time_window': (-0.2, 0.6),
    'conditions': ['Happy', 'Fear', 'Sad'],
    'preprocessing': {
        'notch_filter': [60, 120],
        'bandpass': [0.5, 40],
        'reference': 'average',
        'rejection_threshold': 100e-6
    }
}

with open('modma_metadata.json', 'w') as f:
    json.dump(metadata, f, indent=2)
```

## 4.4 Resumen del proceso ETL

En resumen, el proceso permitió pasar de datos crudos heterogéneos (EEG en formato .raw y variables clínicas en Excel) a un dataset integrado, consistente y optimizado para el análisis posterior.

**Pipeline completo:**

1. Extracción: Lectura de archivos .raw y .xlsx
2. Preprocesamiento EEG: Filtrado y re-referenciación
3. Segmentación: Creación de epochs
4. Rechazo de artefactos: Control de calidad
5. Integración: Merge de EEG con datos clínicos
6. Validación: Verificaciones de consistencia
7. Carga: Exportación a formato Parquet

El código completo del pipeline ETL está disponible en el Apéndice A, permitiendo la reproducibilidad completa del proceso.

Chapter 5

Análisis Exploratorio de Datos (EDA)

En este capítulo se presentan los resultados del análisis exploratorio de datos, diferenciando entre variables clínicas y señales neurofisiológicas. El objetivo es caracterizar las diferencias entre los grupos MDD y HC, identificar patrones relevantes y generar hipótesis para el modelado predictivo.

5.1 Variables Clínicas

5.1.1 Diccionario de variables

Para facilitar la interpretación, se presenta primero un resumen de las variables clínicas analizadas:

| TABLE 5.1: Variables clínicas del estudio |                                                           |
|-------------------------------------------|-----------------------------------------------------------|
| Variable                                  | Descripción                                               |
| PHQ-9                                     | Cuestionario de 9 ítems para síntomas depresivos (0-27)   |
| GAD-7                                     | Cuestionario de 7 ítems para ansiedad generalizada (0-21) |
| CTQ-SF                                    | Trauma infantil: abuso y negligencia (25-125)             |
| LES                                       | Eventos vitales estresantes                               |
| SSRS                                      | Escala de apoyo social percibido (12-66)                  |
| PSQI                                      | Índice de calidad del sueño (0-21)                        |
| Age                                       | Edad en años                                              |
| Education                                 | Años de educación formal completados                      |

5.1.2 Distribución de variables clínicas por grupo

La Figura 5.1 muestra las distribuciones de las variables numéricas diferenciadas por grupo (MDD en rojo y HC en azul). Se observan patrones consistentes con el perfil clínico esperado:




FIGURE 5.1: Distribución de variables clínicas por grupo (MDD vs HC). Las líneas verticales punteadas indican las medianas de cada grupo.

### Hallazgos principales:

- **PHQ-9:** El grupo MDD presenta puntuaciones significativamente más altas (mediana  $\approx 15$ ), indicando depresión moderada-severa, mientras HC muestra valores mínimos (mediana  $\approx 2$ ).
- **GAD-7:** Similar al PHQ-9, con mayor ansiedad en MDD (mediana  $\approx 10$ ) vs HC (mediana  $\approx 2$ ), confirmando la comorbilidad ansiedad-depresión.
- **PSQI:** Los pacientes MDD reportan peor calidad de sueño (mediana  $\approx 12$ ) comparado con HC (mediana  $\approx 4$ ), reflejando los trastornos del sueño característicos de la depresión.
- **SSRS:** Tendencia inversa donde HC presenta mayor apoyo social percibido que MDD, consistente con la literatura sobre aislamiento social en depresión.
- **CTQ-SF y LES:** Aunque con mayor variabilidad, MDD tiende a reportar más trauma infantil y eventos vitales estresantes.
- **Age y Education:** Las distribuciones son similares entre grupos, sugiriendo que el matching de participantes fue adecuado.

### 5.1.3 Análisis de correlación

La Figura 5.2 muestra la matriz de correlación entre las variables clínicas y el grupo diagnóstico.




FIGURE 5.2: Matriz de correlación entre variables clínicas y grupo (MDD vs HC). Los colores más intensos indican correlaciones más fuertes.

#### Correlaciones con diagnóstico (Group):

- **Correlación positiva fuerte:** PHQ-9 ( $r \approx 0.85$ ), GAD-7 ( $r \approx 0.72$ ), PSQI ( $r \approx 0.68$ )
- **Correlación negativa moderada:** SSRS ( $r \approx -0.45$ )
- **Correlación débil:** Age, Education (como se esperaba)

#### Correlaciones entre variables:

- PHQ-9 y GAD-7 están altamente correlacionadas ( $r \approx 0.78$ ), reflejando la superposición sintomática entre depresión y ansiedad.
- PHQ-9 y PSQI también muestran correlación fuerte ( $r \approx 0.65$ ), indicando que los síntomas depresivos se asocian con peor calidad del sueño.
- SSRS se correlaciona negativamente con PHQ-9 y GAD-7, confirmando que menor apoyo social se vincula con mayor sintomatología.

#### 5.1.4 Implicaciones para el modelado

Estos hallazgos tienen varias implicaciones:

1. Las variables clínicas son altamente predictivas del diagnóstico, estableciendo un baseline fuerte para comparar con modelos basados en EEG.
2. La multicolinealidad entre PHQ-9, GAD-7 y PSQI sugiere que podrían utilizarse técnicas de reducción de dimensionalidad.
3. El éxito de un modelo basado únicamente en EEG debería compararse contra un modelo que use estas variables clínicas de referencia.

## 5.2 Datos de EEG

El análisis exploratorio de los datos de EEG parte de la organización en **trials**. Cada *trial* corresponde a una ventana temporal de registro de la señal eléctrica cerebral desde  $-0.2$  segundos antes del estímulo hasta  $0.6$  segundos después.

### 5.2.1 Distribución de trials

La Figura 5.3 muestra la distribución del número de trials por paciente y condición.




FIGURE 5.3: Número de trials por paciente y condición (Fear, Happy, Sad). Cada barra representa un participante individual.

#### Observaciones:

- El número de trials por participante varía considerablemente (rango: 150-280 trials)
- Esta variabilidad se debe a diferencias en el rechazo de artefactos entre participantes
- La distribución entre condiciones (Fear, Happy, Sad) es relativamente balanceada dentro de cada participante
- Total: **12,024 trials** a través de 53 participantes

### 5.2.2 Distribución de amplitudes

La Figura 5.4 presenta la distribución de la amplitud de la señal en el momento crítico de  $0.300$  segundos después del estímulo, correspondiente al componente P2.






FIGURE 5.4: Distribución de la señal a 0.300 segundos por grupo (MDD vs HC). Las distribuciones muestran forma aproximadamente normal centrada en cero.

#### Características:

- Ambas distribuciones (MDD y HC) son aproximadamente normales
- Centradas en torno a cero con desviación estándar similar ( $\sigma \approx 5\text{-}7 \mu\text{V}$ )
- Ligera diferencia en las colas, con MDD mostrando más valores extremos
- Esto confirma que el preprocesamiento (filtrado, re-referenciación) fue efectivo

### 5.2.3 Potenciales evocados promedio (ERPs)

La Figura 5.5 muestra los potenciales evocados promedio por condición y grupo, el análisis más informativo desde la perspectiva neurocientífica.




FIGURE 5.5: Potenciales evocados promedio (ERPs) por condición (Happy, Sad, Fear) en ambos grupos (MDD y HC). Las áreas sombreadas representan el error estándar.

#### Componentes ERP identificados:

1. **P1 ( 100 ms):** Primer pico positivo, similar entre grupos
2. **N1 ( 150 ms):** Deflexión negativa, ligeramente atenuada en MDD
3. **P2 ( 250 ms):** Pico positivo prominente, principal diferencia entre grupos
4. **N2 ( 350 ms):** Componente negativo, variable entre condiciones
5. **LPP (400-600 ms):** Potencial positivo tardío, asociado a evaluación emocional

#### Diferencias entre grupos:

- **Amplitud del P2:** El grupo HC muestra mayor amplitud del P2 que MDD, especialmente en condición Happy
- **Latencia:** Ligero retraso en los componentes tardíos (N2, LPP) en MDD
- **Modulación emocional:** HC presenta mayor diferenciación entre condiciones emocionales que MDD
- **LPP atenuado:** El potencial positivo tardío es menor en MDD, sugiriendo procesamiento emocional reducido

### 5.2.4 Mapas topográficos de actividad cerebral

Los mapas topográficos permiten visualizar la distribución espacial de la actividad eléctrica sobre el cuero cabelludo.

#### Análisis de caso individual

La Figura 5.6 muestra la actividad de un paciente con MDD frente a los tres tipos de estímulos.




FIGURE 5.6: Mapas topográficos para un paciente con MDD bajo estímulos de tristeza (izquierda), felicidad (centro) y miedo (derecha) en la ventana 280-320 ms.

#### Patrones observados:

- **Tristeza (Sad):** Mayor actividad en zonas posteriores (occipital-parietal)
- **Felicidad (Happy):** Mayor concentración en áreas frontales superiores y centrales
- **Miedo (Fear):** Patrón intermedio con activación fronto-central y parietal
- Los diferentes estímulos emocionales evocan patrones topográficos distintivos, confirmando que el paradigma experimental es efectivo

### Comparación entre grupos

La Figura 5.7 presenta la comparación de la actividad promedio de todos los pacientes MDD y HC bajo un estímulo de felicidad.




FIGURE 5.7: Comparación de mapas topográficos promedio entre pacientes MDD (izquierda) y HC (derecha) bajo un estímulo de felicidad (280–320 ms, componente P2).

#### Diferencias clave:

- **HC:** Mayor activación en áreas posteriores y occipitales (procesamiento visual intensificado de estímulos positivos)
- **MDD:** Actividad más concentrada en zonas frontales con menor activación posterior
- **Amplitud general:** HC muestra mayor amplitud de respuesta que MDD
- **Lateralización:** HC presenta ligera lateralización derecha, mientras MDD es más bilateral

### 5.2.5 Correlación intra- e inter-sujeto

Para evaluar la independencia de los *trials* y la consistencia interna de cada participante, se calculó la **correlación intra-sujeto promedio**. Este análisis cuantifica qué tan similares son los patrones de EEG entre diferentes *trials* de un mismo sujeto, considerando todas las características (canales y tiempos) vectorizadas y estandarizadas.




FIGURE 5.8: Correlación intra-sujeto promedio por grupo (MDD vs HC). No se observaron diferencias significativas entre grupos ( $p = 0.7704$ ).

#### Estadísticas descriptivas:

- Correlación promedio intra-sujeto: **0.0336**
- Desviación estándar: 0.0191
- Mínimo: -0.0015
- Máximo: 0.0952
- Mediana: 0.0290

#### Comparación inter-sujeto:

- Correlación promedio inter-sujeto: **0.0075**
- Ratio intra/inter: **4.46x**

**Interpretación:** La correlación intra-sujeto es significativamente mayor que la inter-sujeto, indicando que los *trials* de un mismo individuo tienden a ser más similares entre sí que respecto a otros participantes. Esto confirma la presencia de *huellas neuronales individuales* y justifica el uso de **validación cruzada por sujeto (Subject-wise Cross-Validation)** para evitar fugas de información durante el entrenamiento y evaluación de modelos predictivos.

#### 5.2.6 Análisis por ventanas temporales

Para identificar las ventanas temporales más discriminativas, se calculó la diferencia promedio entre grupos en cada punto temporal:

TABLE 5.2: Diferencias MDD-HC por ventana temporal

| Ventana    | Componente | Diferencia ( $\mu V$ ) | p-valor           |
|------------|------------|------------------------|-------------------|
| 80-120 ms  | P1         | -0.5                   | 0.234             |
| 150-200 ms | N1         | 0.8                    | 0.089             |
| 250-300 ms | P2         | -2.3                   | <b>&lt; 0.001</b> |
| 350-400 ms | N2         | 1.1                    | <b>0.012</b>      |
| 450-550 ms | LPP        | -1.7                   | <b>0.003</b>      |

Las ventanas 250-300 ms (P2) y 450-550 ms (LPP) muestran las diferencias más significativas, sugiriendo que estos intervalos serán los más informativos para el modelado predictivo.

### 5.3 Síntesis del análisis exploratorio

El análisis exploratorio revela varios hallazgos importantes:

#### 5.3.1 Variables clínicas

- Las variables clínicas (PHQ-9, GAD-7, PSQI, SSRS) discriminan fuertemente entre MDD y HC
- Existe multicolinealidad entre cuestionarios, especialmente PHQ-9 y GAD-7
- Estas variables establecen un baseline de desempeño para comparar con modelos basados en EEG

#### 5.3.2 Señales EEG

- Los ERPs muestran diferencias consistentes entre MDD y HC, especialmente en componentes P2 y LPP
- Los mapas topográficos revelan patrones de activación espacial distintivos
- La modulación emocional (diferencias entre Happy, Sad, Fear) es mayor en HC que en MDD
- Las ventanas temporales 250-300 ms y 450-550 ms son las más discriminativas

#### 5.3.3 Implicaciones para el modelado

Estos hallazgos sugieren que:

1. Un modelo basado en EEG debería enfocarse en las ventanas temporales críticas (P2, LPP)
2. La información espacial (topografía) y temporal (evolución del ERP) ambas contienen información relevante
3. Arquitecturas de deep learning que capturen dependencias espacio-temporales (ej: CNN-LSTM, Transformers) podrían ser especialmente efectivas

4. La comparación del desempeño entre modelos con EEG solo vs EEG + variables clínicas permitirá cuantificar el valor agregado de los biomarcadores neurofisiológicos
5. Los *trials* pueden ser utilizados tanto de forma independiente, tratándose cada uno como una observación separada, como promediados en forma de **ERP** agrupado por sujeto para resaltar componentes consistentes y mejorar la relación señal/ruido

## Chapter 6

# Marco Teórico y Revisión de Literatura

Este capítulo presenta el fundamento teórico que sustenta el proyecto, abarcando aspectos neurobiológicos de la depresión, fundamentos de electroencefalografía, y el estado del arte en aplicación de machine learning a diagnóstico neuropsiquiátrico.

## 6.1 Neurobiología de la Depresión Mayor

### 6.1.1 Epidemiología y relevancia clínica

El Trastorno Depresivo Mayor (TDM) es uno de los trastornos mentales más prevalentes a nivel mundial. La Organización Mundial de la Salud (OMS) estima que más de 280 millones de personas viven con depresión, representando aproximadamente el 3.8% de la población global (World Health Organization, 2024).

#### Características epidemiológicas:

- **Prevalencia:** 5-6% en adultos (12 meses), 10-15% (lifetime)
- **Género:** Aproximadamente 2:1 mujer:hombre
- **Edad de inicio:** Típicamente en adultos jóvenes (20-30 años)
- **Carga de enfermedad:** Principal causa de discapacidad a nivel mundial (DALYs)
- **Impacto económico:** > 1 billón USD anuales en productividad perdida

### 6.1.2 Bases neurobiológicas

La depresión se asocia con alteraciones en múltiples sistemas cerebrales:

#### Circuitos neuronales afectados

1. **Corteza prefrontal dorsolateral (DLPFC):** Hipoactividad asociada a síntomas cognitivos (concentración, toma de decisiones)
2. **Corteza cingulada anterior (ACC):** Disfunción en procesamiento emocional y detección de conflicto
3. **Amígdala:** Hiperactividad relacionada con procesamiento de amenaza y valencia negativa

4. **Hipocampo:** Reducción de volumen y neurogénesis, asociada a memoria y regulación del eje HPA
5. **Estriado ventral:** Hipoactividad vinculada a anhedonia (incapacidad para experimentar placer)

#### Sistemas de neurotransmisores

- **Serotonina:** Regulación del humor, apetito y sueño
- **Noradrenalina:** Energía, alerta y motivación
- **Dopamina:** Sistema de recompensa y motivación
- **Glutamato/GABA:** Balance excitatorio-inhibitorio

#### 6.1.3 Modelos teóricos

##### Modelo de sesgo atencional negativo

Los pacientes con depresión muestran sesgos cognitivos hacia información de valencia negativa, lo cual se manifiesta en:

- Mayor atención a estímulos negativos (tristeza, amenaza)
- Reducida respuesta a estímulos positivos
- Interpretación negativa de información ambigua
- Memoria preferencial para eventos negativos

Estos sesgos son evidentes en estudios de ERP, donde se observan diferencias en componentes como el Late Positive Potential (LPP) en respuesta a estímulos emocionales.

## 6.2 Electroencefalografía (EEG)

### 6.2.1 Fundamentos fisiológicos

La EEG mide la actividad eléctrica cerebral generada por la actividad sincrónica de poblaciones neuronales. Específicamente, registra los potenciales postsinápticos de neuronas piramidales en la corteza cerebral.

#### Características de la señal EEG:

- **Amplitud:** Típicamente 10-100  $\mu$ V en cuero cabelludo
- **Frecuencia:** 0.5-100 Hz (bandas clínicamente relevantes)
- **Resolución temporal:** Milisegundos (excelente)
- **Resolución espacial:** Centímetros (limitada)



### 6.2.2 Bandas de frecuencia

TABLE 6.1: Bandas de frecuencia EEG y sus correlatos funcionales

| Banda              | Rango (Hz) | Correlatos funcionales                            |
|--------------------|------------|---------------------------------------------------|
| Delta ( $\delta$ ) | 0.5-4      | Sueño profundo, procesos inconscientes            |
| Theta ( $\theta$ ) | 4-8        | Memoria, emoción, somnolencia                     |
| Alpha ( $\alpha$ ) | 8-13       | Relajación con ojos cerrados, inhibición cortical |
| Beta ( $\beta$ )   | 13-30      | Procesamiento activo, alerta, ansiedad            |
| Gamma ( $\gamma$ ) | 30-100     | Integración sensorial, conciencia                 |

### 6.2.3 Potenciales Evocados Relacionados con Eventos (ERP)

Los ERPs son respuestas cerebrales temporalmente vinculadas a eventos específicos (estímulos, respuestas motoras, procesos cognitivos). Se obtienen promediando múltiples trials para eliminar actividad de fondo no relacionada.

#### Componentes ERP relevantes para depresión

1. **P1 (80-120 ms):**

- Procesamiento visual temprano
- Generado en corteza visual extraestriada
- Típicamente no afectado en depresión

2. **N1 (120-200 ms):**

- Atención selectiva visual
- Puede estar atenuado en depresión
- Refleja filtrado de información irrelevante

3. **P2 (200-300 ms):**

- Detección de características relevantes
- Reducido en respuesta a estímulos positivos en MDD
- Asociado a procesamiento emocional temprano

4. **N2 (300-400 ms):**

- Procesamiento de conflicto y control cognitivo
- Modulado por tipo de estímulo emocional
- Relacionado con función de corteza cingulada anterior

5. **P3/LPP (400-600+ ms):**

- Evaluación emocional profunda y significancia motivacional
- Atenuado en depresión, especialmente para estímulos positivos
- Biomarcador prometedor para MDD

### 6.2.4 EEG en el estudio de la depresión

Investigaciones recientes han identificado varios biomarcadores EEG potenciales para MDD:

- **Asimetría frontal alpha:** Mayor actividad alpha en hemisferio izquierdo (hipoactivación) asociada con depresión y anhedonia
- **Conectividad funcional:** Alteraciones en conectividad entre regiones frontales y posteriores
- **ERPs emocionales:** Modulación reducida del LPP por valencia emocional
- **Complejidad de la señal:** Reducción de complejidad y variabilidad en MDD

## 6.3 Machine Learning en Neuropsiquiatría

### 6.3.1 Motivación para enfoques de ML/DL

Los métodos tradicionales de análisis de EEG (análisis de componentes individuales, análisis espectral) tienen limitaciones:

- Requieren selección manual de características
- Asumen linealidad en las relaciones
- No capturan interacciones complejas espacio-temporales
- Sensibles a decisiones de preprocesamiento

El machine learning y especialmente deep learning ofrecen ventajas:

- **Aprendizaje de características:** Extracción automática de patrones relevantes
- **Modelado no-lineal:** Captura de relaciones complejas
- **Integración multimodal:** Combinación de EEG con otras fuentes de datos
- **Escalabilidad:** Manejo de alta dimensionalidad

### 6.3.2 Estado del arte

#### Métodos tradicionales de ML

Estudios previos han aplicado clasificadores tradicionales a datos EEG:

- **Support Vector Machines (SVM):** Accuracy 70-80% (Simmatitis, Reilly, McConnell, et al., 2023)
- **Random Forest:** Performance similar a SVM con mejor interpretabilidad
- **Regresión logística:** Baseline simple pero efectivo

**Limitación:** Requieren ingeniería manual de características (extracción de power en bandas de frecuencia, amplitud de componentes ERP, etc.)

## Enfoques de Deep Learning

Arquitecturas recientes específicas para datos EEG:

### 1. Convolutional Neural Networks (CNN):

- Capturan patrones espaciales (topografía) y temporales
- EEGNet: arquitectura compacta optimizada para EEG
- Accuracy reportado: 75-85% (Ay, Yildirim, Talo, et al., 2019)

### 2. Recurrent Neural Networks (RNN/LSTM):

- Modelan dependencias temporales de largo plazo
- Efectivos para capturar dinámica de ERPs
- Pueden sufrir de gradientes evanescentes

### 3. Transformers:

- Mecanismo de atención para pesar importancia de diferentes tiempos/electrodos
- Estado del arte en muchas tareas de series temporales
- Computacionalmente costosos

### 4. Arquitecturas híbridas (CNN-LSTM):

- CNN para extracción de características espaciales
- LSTM para modelar evolución temporal
- Accuracy reportado: 80-90% (Lin et al., 2024; Ying et al., 2024)

## 6.3.3 Desafíos y consideraciones

### Tamaño de muestra

Los modelos de deep learning típicamente requieren grandes cantidades de datos. Con 53 sujetos, enfrentamos limitaciones:

- Riesgo de overfitting
- Validación cuidadosa necesaria (leave-one-subject-out)
- Considerar data augmentation y transfer learning

### Interpretabilidad

Los modelos de deep learning son "cajas negras", pero la interpretabilidad es crucial en aplicaciones clínicas:

- **Attention maps:** Visualizar qué regiones/tiempos son más importantes
- **Saliency maps:** Identificar electrodos críticos
- **Feature importance:** Cuantificar contribución de diferentes inputs

Generalización

Factores que afectan la generalización:

- Variabilidad entre sujetos (diferencias anatómicas, conductancia de piel)
- Variabilidad entre sesiones (fatiga, estado emocional)
- Diferencias entre equipos y protocolos de adquisición
- Características demográficas de la muestra (edad, género, etnia)

6.4 Trabajos relacionados

6.4.1 Revisión sistemática de Simmatis et al. (2023)

Simmatis, Reilly, McConnell, et al. (2023) realizaron una revisión exhaustiva de biomarcadores EEG en depresión mayor. Hallazgos clave:

- **Asimetría frontal alpha:** Biomarcador más estudiado, pero con tamaños de efecto moderados
- **ERPs:** P300 y LPP muestran diferencias consistentes entre MDD y HC
- **Heterogeneidad:** Gran variabilidad en metodologías limita comparabilidad
- **Recomendación:** Necesidad de protocolos estandarizados y datasets compartidos

6.4.2 Deep learning con EEG (Ay et al., 2019)

Ay, Yildirim, Talo, et al. (2019) desarrollaron un modelo basado en CNN-LSTM para clasificación de depresión:

- Dataset: 30 MDD, 30 HC
- Paradigma: Resting state EEG (5 minutos)
- Accuracy: 94.7% (validación cruzada 10-fold)
- Limitación: Posible optimismo por no usar leave-one-subject-out

6.4.3 Comparación de ML tradicional vs DL (Lin et al., 2024)

Lin et al. (2024) compararon múltiples enfoques en el mismo dataset:

TABLE 6.2: Comparación de métodos (adaptado de Lin et al., 2024)

| Método             | Accuracy | F1-Score |
|--------------------|----------|----------|
| SVM                | 76.3%    | 0.74     |
| Random Forest      | 78.1%    | 0.76     |
| CNN                | 82.5%    | 0.81     |
| LSTM               | 79.8%    | 0.78     |
| CNN-LSTM (híbrido) | 85.2%    | 0.84     |

**Conclusión:** Los modelos híbridos superan enfoques tradicionales y arquitecturas de DL simples.

#### 6.4.4 EDT: Modelo basado en atención (Ying et al., 2024)

Ying et al. (2024) propusieron EDT (EEG Depression Transformer), un modelo basado en mecanismos de atención:

- Captura dependencias de largo plazo sin limitaciones de RNNs
- Permite interpretabilidad vía attention weights
- Accuracy: 87.3% en dataset multicentro
- Identifica electrodos frontales y temporales como más discriminativos

### 6.5 Propuesta de este trabajo

Basándonos en la revisión de literatura, este proyecto propone:

1. **Análisis exploratorio exhaustivo:** Caracterizar diferencias MDD-HC en múltiples niveles (componentes ERP, topografía, ventanas temporales)
2. **Comparación de arquitecturas:** Evaluar CNN, LSTM, y modelos híbridos en el mismo dataset
3. **Validación rigurosa:** Leave-one-subject-out cross-validation para evitar optimismo
4. **Interpretabilidad:** Identificar biomarcadores específicos mediante análisis de attention/saliency
5. **Valor clínico:** Evaluar si EEG solo puede igualar o superar desempeño de cuestionarios clínicos

El objetivo es contribuir tanto al entendimiento neurocientífico de la depresión como al desarrollo de herramientas diagnósticas prácticas.

## Chapter 7

# Metodología de Modelado

Este capítulo describe los modelos predictivos utilizados para la clasificación de sujetos con Trastorno Depresivo Mayor (MDD) a partir de señales EEG, los fundamentos teóricos que los sustentan, la metodología de validación empleada y las métricas utilizadas para la evaluación de desempeño.

### 7.1 Modelos Utilizados

Se implementaron y compararon cinco modelos de clasificación supervisada, cada uno con configuraciones y características específicas:

- **Random Forest (RF):** Ensamble de árboles de decisión que combina múltiples predictores para reducir la varianza y evitar sobreajuste.
- **MLP + PCA (whiten):** Perceptrón Multicapa con entradas reducidas mediante Análisis de Componentes Principales con blanqueamiento.
- **MLP sin PCA (EEG 1/3):** Red neuronal entrenada con un subconjunto de los canales EEG más relevantes según análisis topográfico.
- **MLP + PCA (0.95 var):** Versión del MLP alimentada con componentes principales que explican el 95% de la varianza.
- **TensorFlow MLP:** Implementación del perceptrón multicapa en TensorFlow, optimizada con técnicas de regularización y early stopping.

### 7.2 Fundamentos Matemáticos

#### 7.2.1 Random Forest

Sea  $\{(x_i, y_i)\}_{i=1}^n$  el conjunto de entrenamiento. Un Random Forest construye  $B$  árboles de decisión  $\{T_b\}_{b=1}^B$  entrenados sobre subconjuntos bootstrap de los datos.

El modelo final realiza votación mayoritaria:

$$\hat{y} = \text{mode}\{T_1(x), T_2(x), \dots, T_B(x)\}$$

Cada árbol selecciona aleatoriamente un subconjunto de variables en cada división, lo que mejora la diversidad del ensamble y reduce la correlación entre árboles.

### 7.2.2 Perceptrón Multicapa (MLP)

Un MLP consiste en capas de neuronas conectadas mediante pesos  $W$  y sesgos  $b$ , aplicando una función de activación no lineal  $\sigma$ :

$$h^{(l)} = \sigma(W^{(l)}h^{(l-1)} + b^{(l)})$$

El objetivo del entrenamiento es minimizar la pérdida binaria:

$$\mathcal{L} = -\frac{1}{n} \sum_{i=1}^n [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)]$$

mediante optimización de gradiente descendente (Adam).

### 7.2.3 Análisis de Componentes Principales (PCA)

PCA transforma los datos originales  $X$  en un nuevo conjunto de variables ortogonales (componentes principales)  $Z = XW$ , donde  $W$  son los autovectores de la matriz de covarianza de  $X$ . El objetivo es maximizar la varianza retenida:

$$\max \text{Var}(Z_k) = w_k^T S w_k, \quad \text{sujeto a } \|w_k\| = 1$$

### 7.2.4 Regularización y Optimización

Para evitar sobreajuste en los MLP se aplicaron:

- Regularización  $L_2$ : penaliza la magnitud de los pesos.
- Dropout: elimina aleatoriamente neuronas durante el entrenamiento.
- Early stopping: detiene el entrenamiento cuando no mejora la pérdida de validación.

## 7.3 Estrategia de Validación

Se empleó validación cruzada estratificada 5-fold, preservando la proporción entre clases (MDD/HC). El conjunto de prueba se mantuvo independiente y no se utilizó durante la selección de hiperparámetros.

## 7.4 Métricas de Evaluación

Las métricas utilizadas fueron:

- **Accuracy**: proporción total de aciertos.
- **Balanced Accuracy**: media del recall entre clases.
- **Recall, Precision, F1-score (MDD)**: centradas en la clase de interés (MDD).
- **AUC**: área bajo la curva ROC.
- **Tiempo de Entrenamiento**: tiempo total de ejecución del modelo.

Todas las métricas se calcularon con base en los valores promedio de las particiones de validación.

## Chapter 8

# Resultados y Análisis Comparativo

Este capítulo presenta los resultados experimentales obtenidos a partir de los modelos descritos en el Capítulo 7, junto con un análisis comparativo del desempeño entre ellos y una discusión sobre sus implicaciones. En esta sección no se incluyen gráficos; todos los resultados se presentan en tablas y en análisis textual para facilitar la reproducción y revisión.

### 8.1 Resultados Individuales

Los resultados promedio por modelo se resumen en la Tabla 8.1.

TABLE 8.1: Desempeño comparativo de los modelos evaluados.

| Modelo                | Acc.  | BalAcc. | Rec.  | Prec. | F1    | AUC   | $\Delta$ Acc | $\Delta$ Bal | $\Delta$ Rec | $\Delta$ F1 | $\Delta$ AUC |
|-----------------------|-------|---------|-------|-------|-------|-------|--------------|--------------|--------------|-------------|--------------|
| Random Forest         | 0.764 | 0.776   | 0.846 | 0.673 | 0.750 | 0.858 | -0.233       | -0.220       | -0.146       | -0.246      | -0.142       |
| MLP + PCA (whiten)    | 0.720 | 0.711   | 0.654 | 0.668 | 0.661 | 0.782 | -0.252       | -0.261       | -0.311       | -0.306      | -0.205       |
| MLP sin PCA (EEG 1/3) | 0.776 | 0.763   | 0.684 | 0.756 | 0.718 | 0.861 | -0.204       | -0.217       | -0.293       | -0.258      | -0.136       |
| MLP + PCA (0.95 var)  | 0.745 | 0.730   | 0.642 | 0.716 | 0.677 | 0.823 | -0.232       | -0.245       | -0.325       | -0.295      | -0.172       |
| TensorFlow MLP        | 0.770 | 0.758   | 0.686 | 0.742 | 0.713 | 0.848 | -0.204       | -0.214       | -0.274       | -0.255      | -0.148       |

El modelo **MLP sin PCA (EEG 1/3)** obtuvo el mejor desempeño general con una **Accuracy de 0.776** y un **AUC de 0.861**, superando levemente al Random Forest. En contraste, los modelos con PCA mostraron una ligera pérdida de rendimiento, lo que sugiere que la reducción de dimensionalidad podría eliminar información discriminativa relevante del EEG.

### 8.2 Análisis Comparativo

A continuación se describen, en forma textual y tabular, las observaciones comparativas más relevantes entre los modelos.

- **Mejor equilibrio (Accuracy vs. Balanced Accuracy):** El MLP sin PCA presenta el mejor balance entre precisión global y balance entre clases.
- **Mayor sensibilidad (recall):** Random Forest muestra el recall más alto (0.846), lo que implica una mayor capacidad para detectar casos positivos (MDD) a costa de una precisión menor.
- **Efecto de PCA:** Las variantes con PCA (whiten y 0.95 var) reportan disminuciones sistemáticas en Recall y F1 en comparación con las redes sin PCA, indicando posible pérdida de información discriminativa.



- **Trade-off eficiencia/desempeño:** MLP + PCA (whiten) tiene el tiempo de entrenamiento más bajo registrado (24.44 s), aunque su desempeño es inferior al de las variantes sin reducción.

### 8.3 Análisis de Errores

El análisis de desempeño revela patrones consistentes en los errores de clasificación entre los modelos evaluados. En ausencia de variables clínicas o demográficas adicionales, el análisis se centra exclusivamente en las diferencias observadas a partir de las métricas agregadas.

- **Brecha entre entrenamiento y prueba:** Los valores negativos de  $\Delta$  en todas las métricas (aproximadamente  $\approx -0.20$ ) indican que el rendimiento durante la validación disminuye frente al obtenido en entrenamiento. Esto sugiere una tendencia general al **sobreajuste**, especialmente en los modelos más complejos como los MLP.
- **Trade-off entre sensibilidad y precisión:** Los modelos con mayor *recall* (como Random Forest) tienden a mostrar una menor *precisión*, lo que implica que aumentan los falsos positivos a cambio de detectar más casos verdaderos. En contraste, los MLP presentan un equilibrio más estable entre ambas métricas.
- **Efecto de la reducción de dimensionalidad:** Las versiones con PCA muestran una pérdida sistemática de *recall* y *F1*, lo que sugiere que al eliminar componentes de baja varianza se descarta información discriminativa relevante del EEG, afectando la capacidad del modelo para identificar correctamente las clases.

En conjunto, los resultados indican que los errores de clasificación provienen principalmente del sobreajuste y de la pérdida de información asociada a la reducción de dimensionalidad. Estos hallazgos orientan los próximos ajustes metodológicos hacia una mejor regularización y validación cruzada más estricta.

### 8.4 Posibles Mejoras

Con base en los resultados obtenidos, se proponen las siguientes mejoras metodológicas:

1. **Aumentar la granularidad temporal:** incorporar secuencias temporales mediante arquitecturas recurrentes (LSTM/GRU) o convolucionales 1D para explotar la dinámica temporal de los ERP.
2. **Optimización de hiperparámetros:** aplicar búsqueda bayesiana o algoritmos evolutivos (Optuna, Hyperopt) para explorar el espacio de parámetros con mayor eficiencia.
3. **Modelos multimodales:** combinar señales EEG con variables clínicas (PHQ-9, GAD-7, CTQ-SF, etc.) mediante fusiones tempranas o tardías para capturar correlaciones complementarias.
4. **Regularización avanzada:** experimentar con dropout programado, batch normalization y técnicas de aumento de datos en el dominio de señales (noise injection, time-shifting).

5. **Explicabilidad y robustez:** incorporar métodos de explicabilidad (SHAP, LIME) y evaluación de robustez frente a artefactos y ruido.

## 8.5 Conclusiones Parciales

Los resultados actuales permiten extraer algunas conclusiones sólidas, aunque preliminares, dado que el proceso de modelado aún se encuentra en desarrollo.

1. **Desempeño general:** El modelo **MLP sin PCA (EEG 1/3)** alcanzó el mejor rendimiento promedio, con una **Accuracy de 0.776** y un **AUC de 0.861**, superando ligeramente al Random Forest. Esto sugiere que las redes neuronales pueden capturar patrones discriminativos relevantes directamente a partir de los datos de EEG sin requerir reducción de dimensionalidad previa.
2. **Efecto del PCA:** Las variantes con PCA (whitening y 0.95 varianza) presentaron disminuciones sistemáticas en métricas como *Recall* y *F1*, lo que indica que la reducción de dimensionalidad podría estar eliminando información útil para la clasificación. En esta etapa, el uso de PCA no mejora el desempeño ni la capacidad de generalización.
3. **Comportamiento de los  $\Delta$  (test - train):** Los valores negativos observados en las métricas ( $\Delta \approx -0.20$ ) reflejan una brecha significativa entre entrenamiento y prueba, lo que evidencia **sobreajuste (overfitting)**. Los modelos tienden a aprender patrones específicos del conjunto de entrenamiento, perdiendo precisión al generalizar.

En conjunto, estos resultados confirman que las señales EEG contienen información discriminativa relevante para la clasificación, pero también señalan la necesidad de aplicar estrategias adicionales de regularización y validación más robustas en las siguientes fases del trabajo.

# Bibliografía

- Ay, B., Ö. Yildirim, A. Talo, et al. (2019). "Automated depression detection using deep representation and sequence learning with EEG signals". In: *Journal of Medical Systems* 43.7. DOI: [10.1007/s10916-019-1345-y](https://doi.org/10.1007/s10916-019-1345-y).
- Lin, H. et al. (2024). "Resting-state electroencephalogram depression diagnosis based on traditional machine learning and deep learning: A comparative analysis". In: *Sensors* 24.21, p. 6815. DOI: [10.3390/s24216815](https://doi.org/10.3390/s24216815).
- Sadeghi, M. et al. (2024). "ERP analysis in emotional attention tasks for major depression". In: *Journal of Affective Disorders* 340, pp. 125–134.
- Simmatis, L., J. Reilly, A. McConnell, et al. (2023). "Technical and clinical considerations for electroencephalography biomarkers in major depressive disorder". In: *Translational Psychiatry* 13. DOI: [10.1038/s44184-023-00038-7](https://doi.org/10.1038/s44184-023-00038-7).
- World Health Organization (2024). *Depressive disorder (depression)*. <https://www.who.int/news-room/fact-sheets/detail/depression>. Accessed: 2025-10-15.
- Ying, M. et al. (2024). "EDT: An EEG-based attention model for feature learning and depression recognition". In: *Biomedical Signal Processing and Control* 97, p. 106182. DOI: [10.1016/j.bspc.2024.106182](https://doi.org/10.1016/j.bspc.2024.106182).