

Aprendizaje Automático de Doble Tarea para la Seguridad Vial: Predicción de la Gravedad de Colisiones y Frecuencia de Accidentes Espacio-Temporal

Adriam Aristizabal^a, Sara Guerra^b

^a*Department of Mathematics and Statistics, Universidad del Norte, Barranquilla 080001, Colombia*

^b*Department of Mathematics and Statistics, Universidad del Norte, Barranquilla 080001, Colombia*

Abstract

Los accidentes de tránsito constituyen un reto crucial para la salud pública y la administración urbana, con repercusiones sociales y económicas a nivel mundial. Este análisis sugiere un método de aprendizaje automático de doble tarea para tratar dos cuestiones fundamentales en la seguridad vial: la predicción de la severidad de los choques y la evaluación espacial y temporal de la frecuencia de los accidentes. Mediante el uso del conjunto de datos US-Accidents, el cual incorpora 7.7 millones de registros georreferenciados de 49 estados de Estados Unidos. (2016-2023), llevamos a cabo un estudio exploratorio multivariado que fusiona métodos estadísticos, geoespaciales y de series de tiempo. La gestión de datos abarcó tácticas sofisticadas para gestionar valores ausentes, outliers físicamente inconsistentes y la incorporación de factores contextuales, como meteorológicos e infraestructura vial.

Keywords: Seguridad vial, aprendizaje multi-tarea, predicción espacio-temporal, gravedad de accidentes, accidentes de tránsito

1. Data

Para el desarrollo del modelo se empleó el conjunto de datos **US-Accidents**, desarrollado por Moosavi et al. (2019) en la Universidad Estatal de Ohio. Esta base de datos surge como una solución ante la limitación de estudios anteriores que, debido a la escasez de datos a gran escala, se vieron obligados a utilizar información local o regional, restringiendo así la generalización de sus hallazgos.

US-Accidents constituye una fuente de datos exhaustiva sobre accidentes de tránsito ocurridos en Estados Unidos, recolectada mediante diversas fuentes como APIs de tráfico en tiempo real, sensores viales y agencias gubernamentales. Entre sus principales características se incluyen:

- **Ubicación geográfica:** Coordenadas GPS precisas del sitio del accidente.
- **Temporalidad:** Fecha y hora de inicio y fin del incidente.
- **Condiciones meteorológicas:** Temperatura, humedad, precipitaciones, visibilidad, velocidad del viento, entre otras.

*Corresponding author.

Email addresses: adriama@uninorte.edu.co (Adriam Aristizabal), guerrams@uninorte.edu.co (Sara Guerra)

- **Infraestructura vial:** Información sobre semáforos, pasos peatonales, gloriets y estaciones de transporte público.
- **Severidad del accidente:** Clasificada en una escala del 1 al 4, de menor a mayor impacto.

Este conjunto de datos, gracias a su riqueza en variables contextuales y cobertura geoespacial, permite realizar análisis y modelos predictivos con mayor precisión y aplicabilidad general.

1.1. Extracción, Transformación y Carga (ETL) para Modelos de Regresión y Clasificación

El desarrollo del conjunto de datos para el análisis de accidentes en California comprendió una serie de etapas metodológicas, abarcando la extracción, transformación y carga de la información.

Fase Inicial Común: Extracción y Preprocesamiento Básico

Inicialmente, para ambas líneas de modelado, se filtraron los registros correspondientes a California y se validó la información esencial. Se transformó la variable temporal `Start_Time` al formato `datetime` y se descartaron aquellos registros que carecían de coordenadas geográficas (`Start_Lat`, `Start_Lng`) válidas.

Posteriormente, se estableció una **discretización espacial** mediante la creación de una grilla que dividió el estado en celdas de aproximadamente 0.05 grados de lado. Cada accidente fue asignado a una celda, generando así un identificador de zona geográfica (`zone_id`). Para el **análisis temporal**, se definió una granularidad semanal, creando identificadores únicos por combinación de zona y semana del año (`year_week`).

A partir de la información de `Start_Time` a nivel de cada accidente, se derivaron variables temporales detalladas como la hora del día, el día de la semana, y se crearon indicadores binarios para fines de semana (`is_weekend`) e incidentes nocturnos (`is_night`). Las variables climáticas (temperatura, humedad, velocidad del viento, precipitación) se procesaron para su limpieza y para la identificación de posibles valores extremos a nivel de evento individual. De manera similar, se incorporaron variables categóricas o binarias relacionadas con la infraestructura vial presente en el lugar del accidente (e.g., presencia de gloriets, estaciones, señales de tráfico). La severidad original de cada accidente también fue registrada en esta etapa. Este conjunto de datos, enriquecido a nivel de cada accidente individual, constituyó la base común antes de la bifurcación del proceso ETL hacia las especificidades de cada tarea de modelado.

Adaptación del ETL para Tareas Específicas

A partir de la base de datos preprocesada a nivel de accidente, el pipeline de ETL se especializó para generar dos conjuntos de datos distintos, cada uno optimizado para su respectiva tarea analítica: regresión y clasificación.

ETL para Modelos de Regresión (Predicción de Frecuencia). El objetivo para la regresión fue predecir la cantidad de accidentes (`accident_count`) por `zone_id` y `year_week`. La transformación clave consistió en la **agregación de datos** a este nivel espacio-temporal. Se calculó `accident_count` como la suma de accidentes. Otras variables, como las climáticas, se promediaron, mientras que los indicadores temporales

(e.g., `is_night`, `is_weekend`), los indicadores de infraestructura como `Junction` o `Traffic.Signal`, y las flags de clima extremo se sumaron para reflejar su ocurrencia o magnitud dentro de cada zona-semana.

Un paso crucial fue asegurar la **completitud temporal del panel de datos**. Para cada `zone_id`, se generaron registros para todas las `year_week` dentro del período de estudio. En las semanas sin incidentes reportados, `accident_count` se imputó con cero, al igual que las sumas de indicadores binarios. Las variables climáticas promedio para estas semanas se rellenaron utilizando la media histórica de la zona, y las coordenadas se mantuvieron consistentes con la zona. Se aplicaron **filtros a nivel de zona** para asegurar la robustez, por ejemplo, conservando zonas con un mínimo de años de datos (`MIN_YEARS`).

En la etapa de **normalización y escalado**, las variables climáticas continuas agregadas fueron estandarizadas (e.g., `StandardScaler`), mientras que variables de conteo, si fuera necesario, podrían someterse a transformaciones como el escalado Min-Max. Un tratamiento específico se dio a la variable de precipitación agregada, donde los valores faltantes (tras la agregación) fueron imputados con cero, bajo la presunción de representar periodos sin lluvia. El producto final de esta rama fue un conjunto de datos estructurado y completo (e.g., `california_accidents_cleaned_complete.csv`), listo para el modelado de regresión de frecuencia.

ETL para Modelos de Clasificación (Predicción de Severidad). Para la tarea de clasificación de la severidad, el proceso se orientó a la generación y uso de un dataset (referido como `reviseddds.csv`) con características específicas. Este dataset, aunque también agregado por `zone_id` y `year_week`, se distingue fundamentalmente por **incluir únicamente aquellas semanas en las que se registró al menos un accidente**.

La variable objetivo es `severity_binary`, derivada de la máxima clase de severidad observada entre los accidentes ocurridos en una `zone_id-year_week` determinada. Si esta máxima severidad alcanzaba un umbral predefinido (e.g., clase 3 o superior), `severity_binary` se marcaba como 1, y 0 en caso contrario. El dataset `reviseddds.csv` contiene, además de `severity_binary`, el `accident_count` para esas semanas activas, promedios climáticos, y sumas de indicadores como `is_night` e `is_weekend`.

Para los modelos benchmark de clasificación, se procedió a una **selección y preprocesamiento adicional de características** a partir de `reviseddds.csv`. Se utilizó un subconjunto reducido de variables, que incluyó un identificador temporal numérico (`temporal_id_numeric`, derivado de `year_week`), `accident_count`, versiones limpias y depuradas de temperatura (`Temperature_F_cleaned`) y precipitación (`Precipitation_in_cleaned`), y las sumas agregadas de `is_night` e `is_weekend`.

El **preprocesamiento de estas características seleccionadas** para los modelos benchmark también contempló la limpieza de nombres de variables, la creación de un identificador espacial coherente (`spatial_id`) y el ya mencionado `temporal_id_numeric`. Las variables numéricas de este conjunto reducido son posteriormente sometidas a un escalado global.

La diferencia fundamental radica en que este enfoque no busca la completitud de todas las semanas, sino que se centra en las características de las semanas donde ocurren accidentes, para modelar la probabilidad de que estos alcancen una alta severidad. Para asegurar la calidad, tanto en la generación de `reviseddds.csv` como en su uso, se pueden aplicar umbrales de actividad mínima (e.g., considerar

solo semanas-zona con un número mínimo de accidentes si se desea refinar más allá de "al menos un accidente").

Resultado del Proceso ETL

El resultado global de este pipeline de ETL diferenciado es la generación de, al menos, dos conjuntos de datos limpios y estructurados: uno exhaustivo y completo para el análisis de regresión de frecuencia, y otro más específico y filtrado para la tarea de clasificación de severidad, cada uno optimizado para los requerimientos de su respectivo enfoque de modelado.

1.2. Análisis Exploratorio de Datos (EDA)

1.2.1. Resumen Estadístico de Variables Numéricas

A continuación, se presentan los principales estadísticos descriptivos de las variables numéricas del conjunto de datos. Estas estadísticas permiten identificar rangos, promedios y variabilidad en aspectos climáticos y de severidad de los accidentes, fundamentales para entender las condiciones generales bajo las cuales se producen los eventos.

Variable	Media	Desv. Estándar	Mínimo	Máximo
Severidad	2.21	0.49	1	4
Temperatura (°C)	16.48	10.56	-67.22	97.22
Visibilidad (km)	14.63	4.33	0	225.31
Humedad (%)	64.83	22.82	1	100
Vel. Viento (km/h)	12.37	8.73	0	1,749.35

Table 1: Estadísticos descriptivos de variables numéricas.

1.2.2. Distribución de Variables Categóricas

El conjunto de datos también permite analizar la distribución de variables categóricas clave, como el estado de procedencia, las condiciones climáticas predominantes, el momento del día y la zona horaria. Por ejemplo, una parte significativa de los registros corresponde al estado de California, con cielos despejados como condición meteorológica predominante, y la mayoría de los accidentes ocurrieron durante el día. Estos patrones proporcionan un contexto útil para la interpretación de los resultados posteriores.

Categoría	Valor	Frecuencia (%)
Estado	California (CA)	22.5
Condición Climática	Cielo Despejado	33.9
Fase del Día	Día	69.2
Zona Horaria	US/Eastern	46.4

Table 2: Distribución de variables categóricas.

1.2.3. Análisis de Valores Faltantes

Algunas variables presentan una proporción moderada de valores faltantes. Por ejemplo, la velocidad del viento tiene un 7.4% de valores ausentes, mientras que la presión y las condiciones climáticas muestran porcentajes menores al 2.5%. Estos valores faltantes requieren estrategias de imputación adecuadas para minimizar su impacto en los modelos predictivos y mantener la integridad del análisis.

Variable	% Faltante
Velocidad del Viento	7.4
Presión	1.8
Condición Climática	2.2

Table 3: Porcentaje de valores faltantes por variable.

1.2.4. Procesamiento de Datos y Manejo de Outliers

Para mejorar la calidad del conjunto de datos, se realizaron diversos procedimientos de limpieza. En primer lugar, se gestionaron valores atípicos extremos. En el caso de la temperatura, se reemplazaron los registros con valores fuera del rango $[-62.2^{\circ}\text{C}, 56.7^{\circ}\text{C}]$ mediante la mediana del estado correspondiente, utilizando la técnica de winsorización. Por su parte, las velocidades del viento superiores a 100 km/h fueron truncadas al percentil 99.5, validando este umbral con datos históricos provenientes de la NOAA.

En cuanto a la categorización climática, se simplificó significativamente el conjunto de condiciones posibles. Se pasó de 144 etiquetas únicas a solo 30 categorías representativas. Esta reducción incluyó una normalización semántica, como la agrupación de términos como “Fair” bajo la categoría “Cielo Despejado”, lo que permite mejorar la interpretabilidad y reducir la dimensionalidad del análisis.

Adicionalmente, se corrigieron inconsistencias temporales. En particular, se identificó que aproximadamente el 8.7% de los registros presentaban tiempos de finalización anteriores a la hora de inicio del accidente, situación que fue corregida para asegurar la coherencia temporal del dataset.

1.2.5. Limitaciones Identificadas

Pese a la riqueza del conjunto de datos, se identificaron algunas limitaciones importantes. En primer lugar, existe un sesgo geográfico, dado que el 68% de los registros provienen de áreas urbanas. Esto podría reducir la representatividad de los accidentes ocurridos en zonas rurales, afectando la generalización de los modelos. En segundo lugar, aunque en proporciones muy reducidas (0.002%), se detectaron valores físicamente imposibles, como temperaturas extremas o velocidades del viento inverosímiles, que podrían afectar análisis más sensibles. Finalmente, se identificó un posible subregistro durante el año 2020, atribuible a la disminución de la movilidad derivada de la pandemia por COVID-19, lo cual podría sesgar los resultados si no se considera adecuadamente.

1.3. Análisis exploratorio para la variable “Severidad”

Esta sección ofrece un estudio exploratorio de datos acerca de la gravedad de los accidentes viales. Se analizan varias variables, entre ellas aspectos dicotómicos, geográficos, temporales, climáticos y de

tráfico, con la finalidad de detectar patrones y vínculos significativos para entender el fenómeno.

1.3.1. Distribución de severidad

La Figura 1 ejemplifica la distribución de la gravedad en el grupo de datos. Se observa una marcada desproporción entre las clases de severidad, por lo cual consideramos necesario el realizar una fusion de clases adyacentes quedando entonces un problema de clasificaciin binaria 0-1, esto causa cierta perdida de informacion y aun tiene la necesidad de aplicar técnicas de balanceo para mejorar la representatividad de los datos, pero se convierte en un problema mucho mas manejabke .




Figure 1: Distribución de la severidad de los accidentes.

1.3.2. Desbalance de Clases y Deriva de Datos

Incluso al consolidar las cuatro clases de severidad originales en una variable binaria (**severity_binary**), se puede observar que persiste un desbalance notable entre las clases resultantes. Más aún, un análisis temporal de la ocurrencia de estas clases revela una ****deriva de datos**** (o *concept drift*). Este fenómeno, donde las propiedades estadísticas de la variable objetivo cambian con el tiempo, es crítico.

Como se visualiza en la Figura 2, la frecuencia de ciertas clases (particularmente la clase de alta severidad en períodos más recientes del conjunto de datos) puede disminuir drásticamente, llegando a un punto donde su predicción se vuelve extremadamente difícil o incluso inviable si la tendencia sugiere una "extinción" de la clase en los datos de entrenamiento futuros.




Figure 2: Visualización de la Deriva de Datos en la Frecuencia de Clases de Severidad a lo Largo del Tiempo.

Esta deriva de datos no solo complica el modelado debido al cambio en la distribución de las clases, sino que también subraya la importancia de utilizar métodos de validación y entrenamiento que puedan manejar esta no estacionariedad. En particular, estrategias como la validación cruzada con ventanas deslizantes o folds temporales específicos (como Leave-Time-Out) se vuelven cruciales para desarrollar modelos que puedan adaptarse a estos cambios y realizar predicciones efectivas. La deriva observada indica que los modelos deben ser reentrenados periódicamente y que la elección de la ventana de entrenamiento es un hiperparámetro clave.

1.3.3. Análisis de Variables Dicotómicas

Se analizó la correlación entre diferentes variables dicotómicas y la gravedad del suceso a través del coeficiente V de Cramer. Este enfoque es más adecuado que el estadístico chi-cuadrado por su menor propensión a muestras de gran envergadura.

Variable	Cramer's V
Amenity	0.0388
Bump	0.0064
Crossing	0.1209
Give Way	0.0094
Junction	0.0535
No Exit	0.0121
Railway	0.0136
Roundabout	0.0023
Station	0.0504
Stop	0.0600
Traffic Calming	0.0062
Traffic Signal	0.1207

Table 4: Valores de Cramer's V para variables dicotómicas.

Aunque los resultados alcanzados son relativamente bajos, resulta crucial tener en cuenta el impacto del desequilibrio de la variable de gravedad en estos resultados. Algunas variables tienen un potencial considerable para análisis futuros.

1.3.4. Análisis de Variables Temporales

La Figura 3 muestra la estructura de los accidentes en función de la hora del día. Se detectaron variaciones en los patrones de gravedad durante el día. Por ejemplo, los incidentes de nivel 4 muestran una estabilidad relativa entre las 07:00 y las 17:00 horas, mientras que los incidentes de nivel 1 y 2 muestran variaciones más significativas en relación al volumen total de accidentes. La severidad 3 también tiene una fluctuación, pero es mucho más suave que la de las dos anteriormente mencionadas.




Figure 3: Distribución de la severidad de los accidentes por hora del día.

1.3.5. Análisis de la Influencia de las Señales de Tráfico

La Figura 4 muestra la relación entre la presencia de señales de tráfico y la severidad de los accidentes. Se evidencia un desequilibrio en la distribución de clases, lo que resalta la necesidad de aplicar métodos robustos de balanceo para garantizar resultados más confiables en estudios posteriores.




Figure 4: Relación entre la presencia de señales de tráfico y la severidad de los accidentes.

1.3.6. Análisis de Correlación de Spearman

El análisis de correlación de Spearman sugiere que las variables meteorológicas tienen un impacto marginal en la severidad de los accidentes. Esto indica que, por sí solas, estas variables podrían no ser suficientemente discriminantes para predecir la severidad del accidente.




Figure 5: Correlación de Spearman entre variables meteorológicas y severidad de los accidentes.

1.3.7. Conclusiones

Los resultados obtenidos en este análisis exploratorio permiten identificar patrones en la severidad de los accidentes en relación con distintas variables.

1.4. Análisis exploratorio para la variable "Accidentes"

En este análisis, se estableció la variable objetivo "**Accidentes**" a partir de los datos geospaciales y temporales de los sucesos viales a través de un método que contempló la agrupación espacial y temporal. Se creó una malla espacial que dividió el área de estudio en celdas de 0.1 unidades, asignando cada suceso a una celda de acuerdo a sus coordenadas. En términos temporales, los sucesos se agruparon por hora, redondeando el tiempo de aparición al comienzo de cada hora para uniformizar los datos. Finalmente, se determinó la variable objetivo al contar la cantidad de incidentes en cada celda y hora determinadas.

1.4.1. Distribución espacial de los accidentes

La representación geográfica de los incidentes en Estados Unidos se muestra en el mapa de accidentes mostrado (Figura 6). Cada punto rojo simboliza un suceso documentado, lo que facilita la identificación de patrones espaciales esenciales.




Figure 6: Mapa geográfico de accidentes en USA

1.4.2. Principales observaciones

Densidad elevada en costas y zonas urbanas: Se nota un incremento en la cantidad de accidentes en las costas este y oeste, poniendo especial atención en áreas metropolitanas de gran envergadura como Nueva York, Los Ángeles y Chicago. Esto podría explicarse por la densidad de población en Estados Unidos, en el cual donde hayan mayor número de personas, así mismo será equivalente el número de accidentes en esa zona.

Patrón de la red de carreteras: La estructura de la red de carreteras interestatales determina la distribución de los accidentes, lo que señala que los corredores de gran tráfico tienen una mayor frecuencia de ocurrir accidentes.

1.4.3. Patrones Temporales y Descomposición de Series de Tiempo

Con el propósito de caracterizar la evolución temporal de los accidentes viales, se efectuó un análisis de series de tiempo, descomponiendo la señal observada en tres componentes principales: tendencia, estacionalidad y residuos.




Figure 7: Descomposición de la serie de tiempo

En lo que respecta a la tendencia, se evidencia un crecimiento sostenido en el número de accidentes a lo largo del período analizado. Este comportamiento presenta una pendiente variable, con un incremento particularmente notorio en torno al año 2020, posiblemente vinculado a cambios en la movilidad urbana durante dicho periodo. Hacia el final de la serie se observa una reducción, que podría interpretarse como una disminución real en la ocurrencia de accidentes o bien como un efecto derivado de inconsistencias en la recolección de datos.

La componente de estacionalidad muestra patrones de repetición en intervalos regulares, lo que sugiere la existencia de ciclos temporales persistentes en la frecuencia de accidentes. Estas variaciones cíclicas pueden asociarse a dinámicas cotidianas de tráfico, como la alternancia entre días laborables y fines de semana, así como a factores estacionales o climáticos.

En cuanto a los residuos, se identifican desviaciones significativas tanto positivas como negativas respecto a la serie ajustada. Estos residuos reflejan la influencia de eventos atípicos no capturados por los componentes estructurales, tales como condiciones meteorológicas extremas, feriados o restricciones extraordinarias en la circulación.




Figure 8: Series de tiempo

El análisis de la distribución horaria de los accidentes revela una marcada concentración en franjas específicas del día, caracterizadas por altos volúmenes de tráfico vehicular. En particular, se observan picos en las primeras horas de la mañana y al final de la tarde, coincidiendo con los horarios típicos de inicio y cierre de actividades laborales y escolares. Este comportamiento refuerza la hipótesis de una relación directa entre la intensidad del tránsito y la frecuencia de accidentes.

Asimismo, la distribución semanal indica una mayor densidad de accidentes durante los días laborales, lo cual podría estar relacionado con la rutina diaria de movilidad urbana. No obstante, se registran también niveles relevantes de siniestralidad durante los fines de semana, lo cual podría estar vinculado a desplazamientos recreativos, viajes interurbanos u otras actividades de carácter social que aumentan el riesgo de incidentes viales.

1.4.4. Relación con la infraestructura




Figure 9: Relación entre la infraestructura vial y la frecuencia de accidentes.

El estudio de la frecuencia de accidentes en diversas clases de infraestructura vial muestra patrones importantes en los lugares críticos de riesgo. Los semáforos se destacan como la infraestructura más vinculada a los accidentes. De forma parecida, las vías peatonales y las intersecciones exhiben una elevada tasa de accidentes, subrayando la importancia de optimizar la señalización, la visibilidad y la administración del tránsito vehicular en estos lugares. En contraposición, infraestructuras tales como paradas de autobuses, cruces de trenes y sistemas de disminución de velocidad muestran una reducción en la frecuencia de accidentes.

1.4.5. Conclusiones

El análisis exploratorio de los accidentes viales ha facilitado la identificación de patrones espaciales y temporales esenciales, ofreciendo una base firme para el modelado predictivo. La división de la información basándose en la localización y el tiempo simplifica la identificación de tendencias, estacionalidades y factores de riesgo vinculados a la aparición de accidentes. Estos descubrimientos aportan datos fundamentales para la elaboración de modelos predictivos, posibilitando calcular la posibilidad de que sucedan accidentes en diversas áreas y momentos basándose en variables geoespaciales y temporales.

2. Modelos

2.1. Modelos Benchmark

Para evaluar la eficacia de nuestros modelos propuestos en la resolución de problemas de clasificación y regresión, implementamos una serie de modelos tradicionales ampliamente utilizados en aprendizaje

automático. Estos modelos sirven como referencia para comparar el desempeño y demostrar cómo nuestra metodología supera a los enfoques convencionales en términos de precisión y robustez.

2.1.1. Clasificación de Bayes

El clasificador *Naive Bayes* es un modelo probabilístico que asume independencia condicional entre las variables predictoras dado el valor de la clase. Esta simplificación permite estimar de forma eficiente las densidades de probabilidad, lo cual resulta particularmente útil en problemas de alta dimensión, donde los métodos de estimación conjunta serían computacionalmente costosos o inestables Hastie et al. (2009).

Formalmente, dado un vector de características $\mathbf{X} = (X_1, X_2, \dots, X_p)$ y una clase $G \in \{1, \dots, K\}$, se modela la razón de probabilidades posterior entre una clase ℓ y una clase de referencia J mediante:

$$\log \frac{P(G = \ell | \mathbf{X})}{P(G = J | \mathbf{X})} = \log \frac{\pi_\ell}{\pi_J} + \sum_{k=1}^p \log \frac{f_{\ell k}(X_k)}{f_{Jk}(X_k)} \quad (1)$$

donde $f_{\ell k}(X_k)$ representa la densidad marginal de la variable X_k condicionada a la clase ℓ , y π_ℓ es la probabilidad a priori de dicha clase.

2.1.2. Regresión Ridge y Lasso

La regresión Ridge y la regresión Lasso son técnicas de regularización utilizadas para mejorar el desempeño predictivo de modelos lineales y prevenir el sobreajuste. Ambas extienden el modelo de regresión lineal clásica mediante la incorporación de un término de penalización en la función de pérdida, el cual restringe los coeficientes del modelo.

La regresión Ridge, también conocida como regularización de Tikhonov, introduce una penalización basada en la norma ℓ_2 de los coeficientes. Su objetivo es minimizar la siguiente función de costo:

$$\min_{\beta} \left\{ \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p x_{ij} \beta_j \right)^2 + \lambda \sum_{j=1}^p \beta_j^2 \right\}$$

donde $\lambda \geq 0$ es un parámetro de regularización que controla la magnitud de la penalización. Esta técnica tiende a reducir la varianza del modelo al permitir coeficientes pequeños pero diferentes de cero.

Por otro lado, la regresión Lasso (Least Absolute Shrinkage and Selection Operator) penaliza los coeficientes utilizando la norma ℓ_1 , lo que no solo reduce la magnitud de los coeficientes, sino que puede llevar a que algunos de ellos se vuelvan exactamente cero, produciendo así un modelo más interpretable mediante selección automática de variables. La función de costo correspondiente es:

$$\min_{\beta} \left\{ \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p x_{ij} \beta_j \right)^2 + \lambda \sum_{j=1}^p |\beta_j| \right\}$$

Ambos métodos requieren la estandarización previa de las variables explicativas para garantizar una aplicación equitativa de la penalización. Para elegir el valor óptimo de λ , es común utilizar validación cruzada. Hastie et al. (2009).

2.1.3. Árboles de Decisión

Un árbol de decisión es un modelo de clasificación jerárquico que particiona recursivamente un conjunto de datos en subconjuntos más homogéneos respecto a la clase objetivo. El algoritmo ID3 selecciona, en cada nodo, el atributo que maximiza la ganancia de información, medida a partir de la entropía:

$$I(p, n) = -\frac{p}{p+n} \log_2 \frac{p}{p+n} - \frac{n}{p+n} \log_2 \frac{n}{p+n}$$

$$\text{gain}(A) = I(p, n) - \sum_{i=1}^v \frac{p_i + n_i}{p+n} I(p_i, n_i)$$

donde p y n representan la cantidad de ejemplos positivos y negativos, respectivamente, y v es el número de particiones posibles del atributo A .

El crecimiento del árbol se detiene cuando los subconjuntos son puros o no quedan atributos disponibles. La simplicidad y explicabilidad del modelo hacen que los árboles de decisión sean especialmente útiles en dominios como el diagnóstico clínico y la toma de decisiones automatizada. Quinlan (1986).

2.1.4. Random Forest

Los bosques aleatorios (*Random Forests*) son un método de ensamblado que construye múltiples árboles de decisión, entrenados sobre subconjuntos aleatorios del conjunto de datos (*bagging*) y utilizando un subconjunto aleatorio de variables en cada división. En clasificación, la predicción final se obtiene por votación mayoritaria, mientras que en regresión se calcula como el promedio de las salidas individuales.

El desempeño del modelo puede analizarse mediante el *margen de clasificación*:

$$mg(X, Y) = \mathbb{E}_k [\mathbb{I}(h_k(X) = Y)] - \max_{j \neq Y} \mathbb{E}_k [\mathbb{I}(h_k(X) = j)]$$

y el error de generalización se define como:

$$PE^* = \mathbb{P}_{X,Y}(mg(X, Y) < 0)$$

Breiman (2001) proporciona una cota superior del error en función de la correlación media entre árboles ($\bar{\rho}$) y la precisión individual promedio (s):

$$PE^* \leq \frac{\bar{\rho}(1 - s^2)}{s^2}$$

Esta técnica mejora la precisión y reduce el sobreajuste, manteniendo buena capacidad de generalización incluso en contextos con alta dimensionalidad. Breiman (2001).

2.1.5. XGBoost

XGBoost (eXtreme Gradient Boosting) es un sistema eficiente y escalable de potenciación de árboles, que ensambla múltiples árboles de decisión para minimizar una función objetivo regularizada. Su diseño se basa en la optimización de segundo orden, con técnicas de regularización y manejo de datos dispersos que lo hacen altamente eficaz para tareas de clasificación, regresión y ranking. La predicción para una instancia se obtiene como suma de funciones $f_k \in \mathcal{F}$, el espacio de árboles:

$$\hat{y}_i = \sum_{k=1}^K f_k(x_i),$$

y la función objetivo se define como:

$$\mathcal{L}(\phi) = \sum_i l(\hat{y}_i, y_i) + \sum_k \Omega(f_k), \quad \text{donde} \quad \Omega(f) = \gamma T + \frac{1}{2} \lambda \|w\|^2.$$

XGBoost se destaca por su capacidad de paralelización, su uso eficiente de memoria y su efectividad para evitar el sobreajuste mediante regularización explícita. Chen and Guestrin (2016).

2.1.6. Support Vector Machines (SVM)

Las Máquinas de Soporte Vectorial (SVM) son métodos supervisados para clasificación y regresión cuyo objetivo es encontrar un hiperplano óptimo que maximice el margen entre clases. En el caso linealmente separable, el margen se maximiza resolviendo una minimización convexa con restricciones $y_i(w \cdot x_i + b) \geq 1$. En contextos no separables, se introducen variables de holgura ξ_i para permitir errores controlados por el parámetro C , que balancea margen y penalización por clasificación incorrecta.

La función de decisión toma la forma:

$$f(x) = \text{sign} \left(\sum_{i \in SV} \alpha_i y_i K(x_i, x) + b \right),$$

lo que permite a las SVM generalizar bien incluso en espacios de características de alta dimensión. Cortes and Vapnik (1995)

2.2. Resultados

2.2.1. Clasificación

2.2.2. Resultados de los Modelos Benchmark

Los resultados de la validación cruzada LTO para los modelos benchmark se resumen en la Tabla 5. Esta tabla presenta las métricas promedio agregadas a través de los folds para las métricas clave, enfocándose en la Clase 1 (alta severidad) y la exactitud general.

Modelo	F1-Score (Clase 1)	Accuracy	Recall (Clase 1)	Precision (Clase 1)
XGBoost (xgb)	0.55	0.73	0.71	0.45
Regresión Logística	0.51	0.71	0.65	0.42
SGD Classifier	0.51	0.71	0.62	0.43
Gaussian Naive Bayes	0.53	0.80	0.47	0.61
K-Nearest Neighbors	0.56	0.79	0.58	0.55

Nota: Estas métricas se derivan de los reportes de clasificación agregados LTO proporcionados.

Table 5: Métricas de Rendimiento Agregado LTO para Modelos Benchmark de Clasificación.

Análisis de Tiempos de Ejecución (Clasificación Benchmark)

La siguiente tabla resume los tiempos promedio de ejecución (en segundos) para el ajuste (‘Fit Time’) y la predicción (‘Predict Time’), así como el tiempo total promedio por cada fold de validación cruzada temporal (LTO). Se comparan las versiones ”Normal” y ”Optimized” de cada modelo. Estos tiempos reflejan el costo computacional promedio incurrido durante la fase de experimentación con LTO.

Algoritmo Base	Versión	Fit Time (s)	Predict Time (s)	Total Time (s)
gaussian_nb	Normal	0.0057	0.0083	0.0141
	Optimized	0.0057	0.0080	0.0136
sgd_log	Normal	0.0575	0.0030	0.0605
	Optimized (SVM)	0.0859	0.0027	0.0886
xgb	Normal	0.1081	0.0430	0.1511
	Optimized	0.1490	0.0512	0.2002
logreg	Normal	0.5100	0.0037	0.5137
	Optimized	3.8085	0.0038	3.8124
rf	Normal	1.1094	0.1859	1.2953
	Optimized	1.2513	0.1832	1.4345
knn	Normal	0.0273	2.0019	2.0292
	Optimized	0.0273	2.1478	2.1752

Table 6: Tiempos Promedio de Ejecución por Modelo y Versión (Segundos por Fold LTO)

si bien en la mayoría de casos el tiempo de ejecución es menor en el caso de regresión usando saga tuvo el efecto contrario, pero de cualquier modo, al tardar una cantidad tan pequeña de tiempo no es considerable y puede también ser atribuida a la variabilidad del hardware en cuestión.

Análisis de cada modelo

A continuación, se presentan los reportes de clasificación detallados y agregados para cada modelo benchmark, basados en la totalidad de las predicciones de los folds LTO:

XGBoost (xgb).

	precision	recall	f1-score	support
Clase 0	0.89	0.74	0.81	279377
Clase 1	0.45	0.71	0.55	86903
accuracy			0.73	366280
macro avg	0.67	0.72	0.68	366280
weighted avg	0.79	0.73	0.75	366280

El modelo XGBoost destaca por su alto recall (0.71) para la Clase 1, indicando una buena capacidad para identificar la mayoría de los accidentes de alta severidad. Sin embargo, esto se logra a expensas de una precisión baja (0.45) para esta misma clase, lo que significa que una proporción considerable de las predicciones de "alta severidad" son falsos positivos. El F1-score de 0.55 para la Clase 1 refleja este compromiso. Para la Clase 0 (baja severidad), la precisión es alta (0.89), pero el recall es moderado (0.74). La exactitud general del modelo es de 0.73. La diferencia entre el F1-score ponderado (0.75) y el macro (0.68) subraya el impacto del rendimiento diferencial entre clases, a pesar del uso de SMOTE en el entrenamiento para balancear las clases.




Figure 10: Gráficos de rendimiento para el Modelo: xgb (Matriz de Confusión, Curva ROC y Curva PR).

Regresión Logística (logreg).

	precision	recall	f1-score	support
Clase 0	0.87	0.72	0.79	279377
Clase 1	0.42	0.65	0.51	86903
accuracy			0.71	366280
macro avg	0.65	0.69	0.65	366280
weighted avg	0.76	0.71	0.72	366280

El modelo de Regresión Logística ('logreg') mostró una capacidad de discriminación decente ($AUC = 0.76$). Su matriz de confusión ('LOGREG1.png') reveló aproximadamente 56,487 Verdaderos Positivos (TP) y 200,000 Verdaderos Negativos (TN). Sin embargo, generó un alto número de Falsos Positivos ($FP \approx 77,054$) y una cantidad considerable de Falsos Negativos ($FN \approx 30,000$), resultando en un Recall para la clase severa de ≈ 0.65 y una Precisión de ≈ 0.42 . La curva PR ('LOGREG3.png') con un Average Precision (AP) de 0.52, sugiere un rendimiento moderado, donde para obtener un recall más alto, la precisión tiende a bajar significativamente.




Figure 11: Gráficos de rendimiento para el Modelo: logreg (Matriz de Confusión, Curva ROC y Curva PR).

El modelo de Regresión Logística (logreg) presentó una capacidad de discriminación aceptable con un AUC de 0.76. Su matriz de confusión reveló una tendencia a generar un número considerable de falsos positivos (aproximadamente 77,000) en comparación con los falsos negativos (alrededor de 30,000), mientras que su curva de Precisión-Recall mostró un Average Precision (AP) de 0.52, indicando un rendimiento moderado en el equilibrio entre precisión y exhaustividad.

SGD Classifier (sgd_log).

	precision	recall	f1-score	support
Clase 0	0.86	0.74	0.80	279377
Clase 1	0.43	0.62	0.51	86903
accuracy			0.71	366280
macro avg	0.65	0.68	0.65	366280
weighted avg	0.76	0.71	0.73	366280

El SGD Classifier presenta un perfil de rendimiento muy similar al de la Regresión Logística, con un F1-score de 0.51 para la Clase 1. Su recall para la Clase 1 es de 0.62, ligeramente inferior al de la regresión logística, mientras que su precisión es marginalmente superior (0.43). La Clase 0 muestra una precisión de 0.86 y un recall de 0.74. La exactitud general (0.71) y el F1-score macro (0.65) son idénticos a los de la Regresión Logística, sugiriendo un comportamiento comparable en esta tarea con la configuración utilizada.




Figure 12: Gráficos de rendimiento para el Modelo: `sgd_log` (Matriz de Confusión, Curva ROC y Curva PR).

Gaussian Naive Bayes (gaussian_nb).

	precision	recall	f1-score	support
Clase 0	0.85	0.90	0.87	279377
Clase 1	0.61	0.47	0.53	86903
accuracy			0.80	366280
macro avg	0.73	0.69	0.70	366280
weighted avg	0.79	0.80	0.79	366280

Gaussian Naive Bayes logra la exactitud general más alta (0.80) entre los modelos benchmark. Para la Clase 1, ofrece la precisión más alta (0.61), lo que implica que cuando predice un accidente como de alta severidad, hay una mayor probabilidad de que sea correcto en comparación con otros modelos. Sin embargo, esto viene acompañado del recall más bajo para la Clase 1 (0.47), lo que significa que no detecta una proporción importante de los casos graves. El F1-score de 0.53 para la Clase 1 es competitivo. El modelo muestra un excelente rendimiento en la Clase 0 (recall de 0.90 y precisión de 0.85). El F1-score macro de 0.70 es el segundo más alto, reflejando un balance razonable a pesar del bajo recall en la clase minoritaria.




Figure 13: Gráficos de rendimiento para el Modelo: `gaussian_nb` (Matriz de Confusión, Curva ROC y Curva PR).

Gaussian Naive Bayes obtuvo un AUC de 0.75 ('GAU2.png'), indicando una capacidad de discriminación similar a 'logreg'. Su matriz de confusión ('GAU1.png') mostró $TN \approx 252,813$, $FP \approx 26,564$, $FN \approx 46,161$ y $TP \approx 40,742$. Este perfil es más conservador al predecir la clase severa, con menos Falsos Positivos pero más Falsos Negativos que 'logreg', lo que se traduce en un Recall de ≈ 0.47 y una Precisión de ≈ 0.60 para la clase severa. Su curva PR ('GAU3.png') tuvo un AP de 0.55, sugiriendo un manejo del compromiso precisión-recall ligeramente mejor.

K-Nearest Neighbors (knn).

	precision	recall	f1-score	support
Clase 0	0.87	0.85	0.86	279377
Clase 1	0.55	0.58	0.56	86903
accuracy			0.79	366280
macro avg	0.71	0.72	0.71	366280
weighted avg	0.79	0.79	0.79	366280

K-Nearest Neighbors (KNN) alcanza el F1-score más alto para la Clase 1 (0.56), proporcionando el mejor equilibrio entre precisión (0.55) y recall (0.58) para la identificación de accidentes de alta severidad entre los modelos evaluados. Su exactitud general es de 0.79, la segunda más alta. El rendimiento en la Clase 0 también es sólido, con una precisión de 0.87 y un recall de 0.85. El F1-score macro de 0.71 es el más alto de todos los benchmarks, lo que sugiere que KNN, bajo esta configuración y con el preprocesamiento SMOTE, logra el desempeño más equilibrado entre las dos clases.




Figure 14: Gráficos de rendimiento para el Modelo: knn (Matriz de Confusión, Curva ROC y Curva PR).

K-Nearest Neighbors ('knn') se destacó con el AUC más alto (0.80, 'KNN2.png') y el AP más elevado (0.56, 'KNN3.png') entre estos tres modelos. Su matriz de confusión ('KNN1.png') presentó $TN \approx 237,062$, $FP \approx 42,315$, $FN \approx 36,131$ y $TP \approx 50,772$. Esto se traduce en un Recall de ≈ 0.58 y una Precisión de ≈ 0.55 para la clase severa, mostrando un balance intermedio de errores y posicionándolo como un clasificador robusto y equilibrado.

2.2.3. Regresión

Dado que el objetivo de este trabajo es desarrollar modelos predictivos que consideren tanto la dimensión temporal como la espacial, se diseñaron dos esquemas de validación complementarios para evaluar el desempeño de los modelos desde ambas perspectivas:

- **Validación temporal (TimeSeriesSplit):** simula escenarios realistas en los que se entrena el modelo con datos históricos para realizar predicciones sobre datos futuros. Este enfoque permite evaluar la capacidad de generalización en el tiempo.
- **Validación espacial (GroupKFold):** consiste en agrupar los datos por unidades geográficas (como municipios o regiones) para entrenar el modelo en ciertos grupos y evaluarlo en otros no vistos. Esto permite estimar la capacidad de generalización espacial a nuevas zonas.

Resultados de los Modelos Benchmark

La siguiente tabla resume los resultados obtenidos para los modelos entrenados bajo los dos esquemas de validación (temporal y espacial). Se reportan métricas de error (RMSE, MAE), coeficiente de determinación (R^2), tiempo de entrenamiento y pruebas estadísticas (Ljung-Box y Jarque-Bera) para evaluar residuos.

Modelo	Tipo	RMSE (Test)	MAE (Test)	R^2 (Test)	L-B p-val	J-B p-val
KNN	Temporal	6.09	3.53	0.42	0.0	0.0
KNN	Espacial	6.07	3.50	0.43	0.0	0.0
RIDGE	Temporal	4.03	2.40	0.75	0.0	0.0
RIDGE	Espacial	4.03	2.40	0.75	0.0	0.0
LASSO	Temporal	5.23	2.89	0.57	0.0	0.0
LASSO	Espacial	5.23	2.89	0.57	0.0	0.0
Random Forest	Temporal	3.90	2.08	0.76	0.0	0.0
Random Forest	Espacial	3.90	2.08	0.76	0.0	0.0
XGBoost	Temporal	3.84	2.12	0.77	0.0	0.0
XGBoost	Espacial	3.84	2.12	0.77	0.0	0.0
SVR	Temporal	4.40	2.44	0.70	0.0	0.0
SVR	Espacial	4.40	2.44	0.70	0.0	0.0

Table 7: Resultados de evaluación en conjunto de prueba para cada modelo (validaciones temporal y espacial)

Án  lisis de cada modelo

KNN. El modelo K-Nearest Neighbors (KNN) mostr   un desempe  o bastante similar en ambas validaciones, con un RMSE de aproximadamente 6.09 en la validaci  n temporal y 6.07 en la espacial, y un MAE cercano a 3.5 en ambos casos. El coeficiente de determinaci  n (R^2) se mantuvo bajo, alrededor de 0.42 y 0.43, lo que indica que el modelo solo explica una proporci  n moderada de la variabilidad en los datos. Esto sugiere que KNN tiene una capacidad limitada para capturar las complejas relaciones subyacentes

en los datos, tanto en el tiempo como en el espacio. Su rendimiento prácticamente idéntico en las dos validaciones también implica que la proximidad local que utiliza no aporta ventajas claras en una dimensión sobre la otra. En resumen, KNN ofrece una predicción básica que puede servir como referencia, pero no es suficiente para modelar adecuadamente la dinámica de los accidentes en este contexto.




Figure 15: Comparación entre las predicciones de KNN espacial y temporal

Análisis de gráficos del modelo KNN




Figure 16: Comparación entre valores reales vs. predichos para KNN en cada validación

En el gráfico de valores reales vs. predichos para la validación **espacial**, se observa una mayor dispersión de los puntos y una tendencia a subestimar los valores altos, lo que concuerda con su bajo coeficiente de determinación R^2 (0.04 en entrenamiento y 0.43 en prueba), indicando que el modelo explica muy poco la varianza de los datos. En contraste, el enfoque **temporal** presenta una alineación algo más estrecha alrededor de la línea de predicción perfecta y mejores métricas de desempeño ($R^2 = 0.38$ en entrenamiento y $R^2 = 0.42$ en prueba), sugiriendo que el modelo temporal captura mejor la estructura del problema.




Figure 17: Comparación entre las autocorrelaciones residuales de KNN para cada validación

En ambos gráficos de autocorrelación de residuos, se observa un pico muy alto en el rezago 0 (como es esperado), pero más importante es que los residuos presentan autocorrelación estadísticamente significativa en múltiples rezagos, lo que indica que no son ruido blanco. Esto se ve respaldado por el valor- p del test de Ljung-Box, que en ambos casos es 0.0000, lo que permite **rechazar la hipótesis nula de no autocorrelación**. Esto sugiere que el modelo *KNN*, en ambos enfoques, **no ha capturado adecuadamente la estructura temporal o espacial de los datos**, dejando patrones residuales no explicados. En resumen, aunque el desempeño del modelo temporal es superior al espacial, ambos presentan **residuos autocorrelacionados**, lo que indica que existen dependencias no modeladas que podrían ser abordadas con modelos más sofisticados.




Figure 18: Comparación entre las distribuciones residuales de KNN para cada validación

Los gráficos de distribución de residuos para las validaciones temporal y espacial del modelo *KNN* muestran diferencias en la dispersión y concentración de los errores. En el modelo espacial, la densidad máxima es mayor (0.10) con errores entre -25 y 125, sugiriendo una concentración de residuos en rangos específicos, aunque con presencia de valores extremos positivos. Por otro lado, el modelo temporal presenta una densidad máxima ligeramente menor (0.08) pero un rango de errores más amplio (-50 a 125), indicando una mayor dispersión y subestimaciones más pronunciadas. Esta combinación sugiere que, aunque los modelos tienen precisión similar, la estructura espacial genera residuos más agrupados con *outliers* positivos, mientras que la validación temporal presenta una variabilidad más amplia y sistemática, posiblemente vinculada a patrones no capturados en el tiempo.

RIDGE. Los resultados del modelo **Ridge** muestran un desempeño muy similar en ambas validaciones (temporal y espacial). En términos de error de prueba, ambos modelos presentan un *Test RMSE* de 4.03 y un *Test MAE* de 2.40, lo que indica una precisión prácticamente idéntica al predecir nuevos datos. La métrica *Test R^2* de 0.75 en ambos casos sugiere que el modelo explica el 75% de la variabilidad en los datos de prueba, reflejando una capacidad predictiva sólida y consistente en ambas dimensiones. Sin embargo, se observan diferencias leves en el rendimiento sobre los datos de entrenamiento, con un ajuste ligeramente mejor en la validación temporal (*Train RMSE* de 3.55 y R^2 de 0.82) comparado con la espacial (RMSE de 3.67, R^2 de 0.78), lo que puede indicar una menor complejidad o mayor estabilidad en los patrones temporales del conjunto de entrenamiento. A pesar del buen ajuste general, los *p*-valores de Ljung-Box y Jarque-Bera son 0.0 en ambos casos, lo que revela que los residuos no son independientes ni normalmente distribuidos. Esto limita la validez de inferencias clásicas basadas en supuestos estadísticos estándar y sugiere la presencia de patrones estructurales o no lineales no capturados por el modelo.




Figure 19: Comparación entre las predicciones de RIDGE espacial y temporal

Análisis de gráficos del modelo RIDGE




Figure 20: Comparación entre valores reales vs. predichos para RIDGE en cada validación

Los gráficos de valores reales vs. predichos para el modelo **Ridge**, tanto en validación espacial como temporal, reflejan un ajuste coherente con las métricas reportadas. La similitud en los rangos de los ejes (0-175) y la presencia de la línea de “Predicción Perfecta” sugieren que las predicciones se alinean cercanamente con los valores reales, especialmente en el conjunto de entrenamiento, respaldado por los altos valores de *Train R^2* (0.82 en la validación temporal y 0.78 en la espacial). La superposición de puntos del conjunto de prueba (*Test*) cerca de esta línea, inferida a partir de los bajos errores (*Test RMSE* = 4.03 en ambos casos) y el valor de *Test R^2* = 0.75, indica una capacidad de generalización aceptable. Sin embargo, la ausencia de normalidad e independencia en los residuos (*p*-valores 0.0) podría

manifestarse como dispersiones asimétricas o agrupamientos no evidentes directamente, lo que señala limitaciones en la captura de patrones complejos.




Figure 21: Comparación entre las autocorrelaciones residuales de RIDGE para cada validación

Los gráficos de función de autocorrelación (ACF) para los residuos del modelo **Ridge**, tanto en validación espacial como temporal, confirman la presencia de dependencia serial, respaldada por los p -valores de Ljung-Box (0.0000). La ACF muestra correlaciones significativas en múltiples rezagos (0-20), con oscilaciones entre -1.00 y 1.00, lo que sugiere patrones cíclicos no capturados por el modelo. La similitud entre ambos gráficos indica que la estructura de dependencia es consistente en ambos dominios, reforzando la idea de que los residuos no son aleatorios, a pesar del buen desempeño predictivo ($Test R^2 = 0.75$). Estas autocorrelaciones persistentes podrían deberse a variables omitidas, efectos no lineales no modelados o estructuras espacio-temporales subyacentes.




Figure 22: Comparación entre las distribuciones residuales de RIDGE para cada validación

Los gráficos de distribución de residuos para el modelo **Ridge**, tanto en validación espacial como temporal, muestran una concentración de errores en rangos reducidos (entre -50 y 125), con densidades máximas alrededor de 50 y 25, respectivamente. Esto sugiere una mayor precisión comparado con KNN, coherente con los bajos valores de $Test RMSE$ (4.03) y $Test MAE$ (2.40). Sin embargo, la asimetría en la distribución (valores positivos extendidos hasta 125) y la no normalidad (p -valor Jarque-Bera = 0.0) revelan colas pesadas y posibles *outliers*, indicando que el modelo subestima sistemáticamente ciertos patrones.

LASSO. El modelo LASSO arrojó un desempeño idéntico en ambas validaciones, temporal y espacial, con un Test RMSE de 5.23, Test MAE de 2.89 y un coeficiente de determinación R^2 de 0.57. Estas métricas lo posicionan por debajo de Ridge en términos de precisión, aunque LASSO se caracteriza por su eficiencia computacional y su capacidad inherente de selección de variables, que puede ser ventajosa en escenarios con alta dimensionalidad.




Figure 23: Comparación entre las predicciones de LASSO espacial y temporal

Análisis de gráficos del modelo LASSO




Figure 24: Comparación entre valores reales vs. predichos para LASSO en cada validación

Los gráficos de valores reales vs. predichos para el modelo **LASSO**, tanto en validación temporal como espacial, muestran una dispersión moderada alrededor de la línea de “Predicción Perfecta”, congruente con las métricas reportadas ($Test R^2$ de 0.57 y $Test RMSE$ de 5.23). Aunque el ajuste es aceptable, resulta inferior al del modelo Ridge. Se destaca un menor $Train R^2$ en la validación espacial (0.27 vs. 0.42 temporal), lo que sugiere dificultades para capturar patrones espaciales durante el entrenamiento. Si bien LASSO es computacionalmente eficiente, la dispersión asimétrica en los gráficos y los errores moderados señalan limitaciones en la precisión, posiblemente vinculadas a una selección de variables demasiado restrictiva por la regularización L1. En síntesis, el modelo ofrece un equilibrio entre velocidad y rendimiento, pero podría requerir ajustes para abordar la estructura residual y mejorar la capacidad predictiva.




Figure 25: Comparación entre las autocorrelaciones residuales de LASSO para cada validación

Los gráficos de función de autocorrelación (ACF) para los residuos del modelo **LASSO**, en validación temporal y espacial, revelan una dependencia serial significativa (p -valor Ljung-Box = 0.0000), con correlaciones que oscilan entre -1.00 y 1.00 en rezagos de 0 a 20. Esto indica patrones cíclicos o tendencias no modeladas, similares a los observados en Ridge y KNN, lo que sugiere una limitación estructural compartida. Aunque LASSO mejora ligeramente el rendimiento predictivo frente a KNN, la persistencia de autocorrelaciones evidencia que no logra capturar completamente los componentes temporales o espaciales subyacentes.





Figure 26: Comparación entre las distribuciones residuales de LASSO para cada validación


La distribución de residuos del modelo **LASSO**, tanto en validación espacial como temporal, presenta una asimetría notable: la cola negativa se extiende hasta -25, mientras que la positiva alcanza aproximadamente +35. Esto sugiere que la mayoría de los residuos se concentran en el rango $[-25, +35]$, con posibles *outliers* escasos más allá de +35, lo que explica el *Test RMSE* (5.23) superior al *Test MAE* (2.89). La densidad máxima (0.12) cerca de cero indica precisión en predicciones centrales, pero la asimetría hacia valores positivos revela una tendencia a subestimar ocasionalmente magnitudes altas, compatible con los bajos *Train R^2* espaciales (0.27). Los p -valores de Ljung-Box y Jarque-Bera (0.0) confirman que, a pesar de la concentración central de errores, persisten dependencia serial y no normalidad, vinculadas a patrones no capturados y *outliers*.

Random Forest. El modelo **Random Forest** muestra un rendimiento superior en comparación con KNN, Ridge y LASSO. Logró valores altos de *Test R^2* (0.76 en ambos dominios, temporal y espacial) y *Train*

R^2 (0.79 temporal, 0.74 espacial), junto a errores reducidos ($Test RMSE \approx 3.90$, $Test MAE \approx 2.08$). Esto refleja una capacidad predictiva robusta y una generalización efectiva entre contextos temporales y espaciales. Sin embargo, al igual que en los modelos anteriores, los p -valores de Ljung-Box y Jarque-Bera (0.0) indican que los residuos carecen de independencia y normalidad, un problema recurrente que sugiere la persistencia de patrones no modelados, como ciclos temporales o interacciones espaciales complejas.




(a) Random Forest espacial




(b) Random Forest temporal

Figure 27: Comparación entre las predicciones de Random Forest espacial y temporal

Análisis de gráficos del modelo Random Forest



(a) Random Forest espacial: Real vs. Predicho



(b) Random Forest temporal: Real vs. Predicho

Figure 28: Comparación entre valores reales vs. predichos para Random Forest en cada validación

Los gráficos de valores reales vs. predichos para el modelo **Random Forest**, tanto en validación temporal como espacial, muestran una agrupación cercana a la línea de “Predicción Perfecta”, respaldando los altos valores de $Test R^2$ (0.76) y los bajos errores ($Test RMSE \approx 3.90$). La concentración de puntos alrededor de esta línea en ambos dominios refleja la capacidad del modelo para generalizar efectivamente. La consistencia entre métricas temporales y espaciales destaca su robustez. En síntesis, **Random Forest** ofrece un excelente equilibrio entre precisión y generalización.




Figure 29: Comparación entre las autocorrelaciones residuales de Random Forest para cada validación





Figure 30: Comparación entre las distribuciones residuales de Random Forest para cada validación


La distribución de residuos del modelo **Random Forest**, tanto en validación temporal como espacial, presenta una asimetría moderada con colas limitadas: la negativa alcanza hasta -15 y la positiva hasta aproximadamente +36. La densidad máxima (0.10) próxima a errores cercanos a cero refleja precisión en predicciones centrales, coherente con los bajos *Test RMSE* (3.90) y *Test MAE* (2.08). Sin embargo, la cola positiva extendida (+36) indica subestimaciones ocasionales en valores altos, mientras que la negativa (-15) sugiere sobreestimaciones menores. Esto contribuye a los p -valores de Jarque-Bera (0.0) que confirman no normalidad residual. La similitud entre dominios ($\text{Test } R^2 = 0.76$ en ambos) destaca consistencia predictiva, pero los p -valores de Ljung-Box (0.0) revelan dependencia serial persistente, asociada a patrones temporales/espaciales no capturados.

XGBoost. Los resultados del modelo **XGBoost** indican un rendimiento predictivo robusto y ligeramente superior al de Random Forest en varias métricas clave. En las pruebas, XGBoost alcanzó un *Test RMSE* de 3.84, *Test MAE* de 2.12 y un *Test R^2* de 0.77 en ambas validaciones (temporal y espacial). En entrenamiento, también mostró valores R^2 ligeramente más altos que Random Forest (0.81 temporal, 0.77 espacial). Esto refleja una alta capacidad de ajuste y una excelente generalización. No obstante, los p -valores de Ljung-Box y Jarque-Bera (0.0) confirman problemas persistentes de dependencia serial y no normalidad en los residuos, similares a los observados en modelos anteriores. Los gráficos de distribución de residuos (analizados a continuación) exhiben colas asimétricas, con errores concentrados cerca de cero pero extendidos hacia valores positivos, indicando subestimaciones ocasionales en magnitudes altas. La

consistencia entre métricas temporales y espaciales sugiere que **XGBoost** maneja bien ambos dominios, aunque persisten limitaciones estructurales no resueltas.




(a) XGBoost espacial




(b) XGBoost temporal

Figure 31: Comparación entre las predicciones de XGBoost espacial y temporal

Análisis de gráficos del modelo XGBoost




(a) XGBoost espacial: Real vs. Predicho




(b) XGBoost temporal: Real vs. Predicho

Figure 32: Comparación entre valores reales vs. predichos para XGBoost en cada validación

Los gráficos de valores reales vs. predichos para **XGBoost**, en validación temporal y espacial, muestran una agrupación cercana a la línea de *Predicción Perfecta*, respaldando los altos valores de *Test R^2* (0.77) y la precisión reflejada en los bajos errores (*Test RMSE* = 3.84, *Test MAE* = 2.12). La distribución de puntos sugiere un buen ajuste en la mayoría de los casos, aunque la asimetría en los residuos (subestimaciones en valores altos) se manifestaría como puntos dispersos por encima de la línea en el rango superior (valores reales $\neq$ predichos).




(a) ACF Residuos XGBoost espacial




(b) ACF Residuos XGBoost temporal

Figure 33: Comparación entre las autocorrelaciones residuales de XGBoost para cada validación



(a) Distribución Residuos XGBoost espacial




(b) Distribución Residuos XGBoost temporal


Figure 34: Comparación entre las distribuciones residuales de XGBoost para cada validación

Los gráficos de distribución de residuos para XGBoost muestran una densidad máxima (0.14) concentrada en errores cercanos a cero, reflejando precisión en la mayoría de las predicciones. Las colas asimétricas se extienden desde aproximadamente -15 hasta +35: la cola negativa (-15) indica sobreestimaciones leves, mientras la positiva (+35) revela subestimaciones más pronunciadas en valores altos. Esta asimetría sugiere dificultades para capturar eventos extremos o patrones específicos, aunque la mayoría de los errores se mantienen en rangos reducidos. La similitud entre los gráficos temporal y espacial destaca consistencia en el comportamiento del modelo, con una distribución residual coherente en ambos dominios.

SVR. El modelo Support Vector Regression (SVR) demostró una consistencia notable entre las validaciones temporal y espacial, alcanzando un Test RMSE de 4.40, un Test MAE de 2.44 y un Test R^2 de 0.70. Este rendimiento lo ubica como una alternativa competitiva, con una capacidad predictiva inferior a los modelos basados en ensambles de árboles pero superior a LASSO y KNN en términos de R^2 .




(a) SVR espacial




(b) SVR temporal

Figure 35: Comparación entre las predicciones de SVR espacial y temporal

Análisis de gráficos del modelo SVR



(a) SVR espacial: Real vs. Predicho



(b) SVR temporal: Real vs. Predicho

Figure 36: Comparación entre valores reales vs. predichos para SVR en cada validación

Los gráficos de valores reales vs. predichos para el modelo SVR, en validación temporal y espacial, muestran una dispersión moderada alrededor de la línea de *Predicción Perfecta*, congruente con el *Test R^2* de 0.70 y los errores reportados. La concentración de puntos cerca del origen (0-100) sugiere un mejor ajuste en valores bajos a medios, mientras que la dispersión en rangos superiores (100-175) indica dificultades para predecir magnitudes altas, posiblemente vinculadas a subestimaciones. La similitud entre gráficos resalta un comportamiento residual homogéneo en ambos contextos. No obstante, como en otros modelos, la asimetría en errores altos y la indicada falta de normalidad y autocorrelación (p -valores de 0.0 para Jarque-Bera y Ljung-Box) limitan su aplicabilidad para inferencias estadísticas robustas sin un tratamiento adicional de los residuos.




Figure 37: Comparación entre las autocorrelaciones residuales de SVR para cada validación




Figure 38: Comparación entre las distribuciones residuales de SVR para cada validación

Los gráficos de distribución de residuos para SVR, tanto temporal como espacial, presentan una densidad máxima baja (0.08) cerca de errores próximos a cero, indicando precisión moderada en predicciones centrales. Las colas asimétricas se extienden desde -15 (cola negativa) hasta +43 (cola positiva), revelando una tendencia marcada a subestimar valores altos, con errores positivos más frecuentes y pronunciados. La distribución muestra una dispersión homogénea en ambos dominios, con errores concentrados en el rango $[-15, +43]$ y densidades decrecientes hacia los extremos. La similitud entre los gráficos temporal y espacial sugiere un comportamiento residual consistente, aunque la asimetría hacia valores positivos destaca limitaciones en la capacidad del modelo para capturar magnitudes elevadas de forma precisa.

Resultados modelos optimizados

Modelo	Tipo	Test RMSE	Test MAE	Test R^2
KNN	Temporal	6.02	3.49	0.43
KNN	Espacial	6.05	3.49	0.43
Ridge	Temporal	4.10	2.35	0.74
Ridge	Espacial	4.10	2.35	0.74
Lasso	Temporal	5.20	2.91	0.58
Lasso	Espacial	5.19	2.91	0.58
Random Forest	Temporal	3.90	2.08	0.76
Random Forest	Espacial	3.90	2.09	0.76
XGBoost	Espacial	3.83	2.12	0.77
SVR Lineal	Temporal	4.21	2.41	0.72
SVR Lineal	Espacial	4.21	2.41	0.72
SVR RBF	Temporal	7.61	4.93	0.10
SVR RBF	Espacial	7.61	4.93	0.10

Table 8: Métricas de evaluación en el conjunto de prueba para modelos optimizados

2.2.4. Comparación de tiempo

Modelo	Duración sin optimizar (s)	Duración optimizado (s)
KNN Temporal	23.76	9.46
KNN Espacial	34.06	9.71
Ridge Temporal	0.65	68.36
Ridge Espacial	0.87	56.68
Lasso Temporal	0.79	4.16
Lasso Espacial	0.91	5.79
Random Forest Temporal	310.56	314.76
Random Forest Espacial	244.43	270.44
XGBoost Temporal	2.92	3.71
XGBoost Espacial	2.53	3.91
SVR (Linear) Temporal	4646.28	35.01
SVR (Linear) Espacial	5094.42	43.19

Table 9: Comparación de duración (segundos) entre modelos sin optimizar y optimizados

Conclusiones

Los modelos basados en árboles de decisión, **XGBoost** y **Random Forest**, demostraron el mejor rendimiento en la predicción de accidentes. En su configuración no optimizada, XGBoost alcanzó un RMSE de 3.84 y un coeficiente de determinación $R^2 = 0.77$, mientras que Random Forest registró valores cercanos (RMSE = 3.90, $R^2 = 0.76$). Tras la optimización, ambos modelos mantuvieron estabilidad en sus métricas (variación $< 1\%$), sugiriendo que su configuración inicial ya estaba próxima al óptimo.

El modelo **SVR con kernel RBF** mostró un comportamiento divergente: en su versión base obtuvo un RMSE de 4.40 ($R^2 = 0.70$), pero tras la optimización sufrió un deterioro drástico (RMSE ≈ 7.6 , $R^2 \approx 0.10$), indicativo de sobreajuste o selección inapropiada de hiperparámetros. Entre los modelos lineales, **Ridge** superó consistentemente a **Lasso**, con un $R^2 = 0.75$ (RMSE = 4.03) frente a $R^2 \approx 0.57$, evidenciando que la regularización menos agresiva de Ridge se adapta mejor a la estructura de los datos. Por su parte, **KNN** mostró eficiencia computacional tras la optimización (reducción de tiempos de ejecución), pero mantuvo precisión limitada ($R^2 \approx 0.43$), inferior a modelos más complejos.

Los análisis estadísticos revelaron patrones críticos en los residuos. El test de **Ljung-Box** arrojó p -valor = 0.0, señalando autocorrelación residual, mientras que el test de **Jarque-Bera** (p -valor = 0.0) confirmó no normalidad en la distribución de errores. Estos resultados implican que los modelos actuales no capturan completamente las dependencias temporo-espaciales ni la estructura estocástica subyacente.

Los modelos **XGBoost** y **Random Forest** emergen como las opciones más precisas y robustas para la tarea, con ventajas significativas sobre alternativas lineales o basadas en kernels. Aunque **Ridge** representa la mejor opción entre los modelos lineales, su desempeño ($R^2 = 0.75$) queda por debajo de los basados en árboles. La inestabilidad de **SVR** tras la optimización subraya la necesidad de validar estratégicamente ajustes de hiperparámetros en contextos específicos. Finalmente, la presencia de autocorrelación y no normalidad sugiere explorar modelos jerárquicos bayesianos o arquitecturas espacio-temporales para mejorar la captura de patrones complejos.

2.3. Modelos Propuestos Avanzados con Procesos Gaussianos

Para superar las limitaciones de los modelos benchmark y abordar de manera más robusta la complejidad inherente a los datos de accidentalidad, se desarrollaron dos enfoques avanzados basados en Procesos Gaussianos (GP): uno para la clasificación de la severidad de los accidentes (ST-GPC) y otro para la regresión de su frecuencia (ST-GPR). Ambos modelos buscan capturar las dependencias espacio-temporales y ofrecer una cuantificación de la incertidumbre en sus predicciones.

2.3.1. Modelo de Clasificación: Procesos Gaussianos Espacio-Temporales por Zona (ST-GPC)

Para abordar la predicción de la severidad de los accidentes en un contexto espacio-temporal, se propone un modelo avanzado basado en Procesos Gaussianos para Clasificación (GPC) con entrenamiento individualizado por zona geográfica (ST-GPC). Este enfoque permite modelar las particularidades de cada zona y su evolución temporal.

Metodología del Modelo ST-GPC

La metodología del ST-GPC se fundamenta en el dataset `revisedds.csv`, el cual, a diferencia de un ETL más general que podría incluir todas las semanas, contiene datos ya agregados por `zone_id` y `year_week`, considerando exclusivamente semanas con al menos un accidente y donde la variable objetivo `severity_binary` se define como 1 si la `max_severity_class` es mayor o igual a 3. Sobre esta base, las preparaciones finales para el GPC incluyen la creación de identificadores `spatial_id` (para 6263 zonas) y `temporal_id_numeric`, junto con la selección, imputación y escalado mediante `StandardScaler` de las covariables de entrada (que abarcan el identificador temporal, `accident_count`, variables climáticas como `Temperature_F_cleaned` y `Precipitation_in_cleaned`, e indicadores como `is_night` e `is_weekend`). Posteriormente, se emplea un estimador `GPyZoneBinaryClassifier` que ajusta un modelo `GPy.models.GPClassification` independiente por `spatial_id`, utilizando como entradas (X) las features escaladas y como salida (Y) la variable `severity_binary`. Dicho modelo se caracteriza por un kernel compuesto $k(x, x') = k_{\text{Matern52}}(x, x'; \text{ARD}) + k_{\text{White}}(x, x')$, donde el Matern52 con ARD opera con varianza restringida a $[10^{-3}, 10]$ y longitudes de escala a $[0.01, 200]$, y el kernel White con varianza fija de 10^{-5} . Se utiliza una función de verosimilitud de Bernoulli (`GPy.likelihoods.Bernoulli()`), la inferencia se realiza mediante aproximación de Laplace, y la optimización de la verosimilitud marginal se efectúa con `num_restarts = 2`. Para mitigar el desbalance de clases, se aplica SMOTE por zona (con `sampling_strategy = 0.5` y `k_neighbors` ajustado dinámicamente) antes del entrenamiento de cada GP zonal, implementando un mecanismo de fallback a la proporción media global de la clase positiva del fold de entrenamiento para zonas nuevas o con fallos en el ajuste. La validación del modelo se realiza mediante un esquema de Validación Cruzada "Leave-Time-Out" (LTO) con 10 folds, empleando una ventana de entrenamiento deslizante de 13 períodos temporales (semanas) y una ventana de prueba de aproximadamente 34-35 períodos. Finalmente, el rendimiento se cuantifica a través de métricas como F1-Score, Recall y Precisión (enfocadas en la Clase 1), así como ROC AUC y Accuracy global.

Resultados del Modelo ST-GPC

La aplicación del ST-GPC arrojó los siguientes resultados promedio y agregados a través de los 10 folds LTO:

Rendimiento Promedio y Agregado del ST-GPC. Las métricas promedio generales a través de los folds LTO fueron:

- F1-Score Promedio (Clase 1): 0.6876 ± 0.1557
- ROC AUC Promedio: 0.8924 ± 0.0299
- Accuracy Promedio: 0.8621 ± 0.0149

El reporte de clasificación agregado para todas las predicciones de los folds LTO es:

	precision	recall	f1-score	support
Clase 0	0.92	0.90	0.91	279377
Clase 1	0.69	0.76	0.72	86903
accuracy			0.86	366280
macro avg	0.81	0.83	0.82	366280
weighted avg	0.87	0.86	0.87	366280




Figure 39: Gráficos de rendimiento para el Modelo: gaussian_nb (Matriz de Confusión, Curva ROC y Curva PR).

Conclusiones

El modelo de Procesos Gaussianos por Zona para Clasificación (ST-GPC), evaluado mediante una rigurosa validación cruzada Leave-Time-Out (LTO) de 10 folds con ventanas de entrenamiento deslizantes de 13 períodos temporales, demostró ser el enfoque más prometedor para la predicción de la severidad binaria de accidentes. En promedio, el ST-GPC alcanzó un F1-score para la Clase 1 (alta severidad) de 0,688 y un ROC AUC de 0,892, indicando una capacidad predictiva y discriminativa considerablemente superior a los modelos benchmark evaluados bajo un esquema comparable. La exactitud (accuracy) promedio del modelo se situó en 0,862. El rendimiento del ST-GPC fue particularmente destacable en los primeros folds de la validación LTO, donde la proporción de la clase positiva en los datos de entrenamiento era más elevada (entre 39 y 44), logrando F1-scores para la Clase 1 que consistentemente superaron el 0,75 e incluso alcanzaron un notable 0,839 en el Fold 3. Este F1-score se sustentó en un excelente recall de 0,82 y una precisión de 0,85 para la clase de alta severidad en dicho fold. A lo largo de los 10 folds, el recall promedio para la Clase 1 fue de 0,684, lo que significa que el modelo fue capaz de identificar aproximadamente el 68 de todas las zona-semanas con alta severidad. La precisión promedio para la Clase 1 fue de 0,701, indicando que cuando el modelo predijo alta severidad, acertó en aproximadamente el 70 de los casos. Aunque se observó una tendencia a la disminución del F1-score y la precisión en los folds correspondientes a períodos temporales más recientes (cayendo el F1 a 0,334 en el último fold), el ROC AUC se mantuvo consistentemente alto (por encima de 0,805 en todos los folds), lo que sugiere que la capacidad fundamental del modelo para distinguir entre clases de severidad

permanece robusta, si bien la calibración para la clasificación directa se vuelve más desafiante ante la creciente escasez de la clase positiva. Las advertencias durante la optimización de los hiperparámetros del kernel GP, aunque persistentes, no impidieron que el modelo alcanzara este nivel de rendimiento, que representa el mejor desempeño equilibrado entre las dos clases de severidad entre todos los enfoques probados. Adicionalmente, es relevante destacar que este modelo de Proceso Gaussiano por Zona para Clasificación (ST-GPC), referido también como el 'proceso gaussiano modificado', no solo demostró ser el más prometedor para la Clase 1, sino que presentó un desempeño superior en general, alcanzando el F1-score más alto entre los modelos evaluados sin incurrir en un tiempo de cómputo excesivamente alto.

Sin embargo, es crucial reconocer una limitación inherente, compartida con el resto de los modelos benchmark evaluados: el modelo tiene dificultades al avanzar en el tiempo del dataset debido a una marcada deriva de los datos. Este fenómeno, donde las características estadísticas de los datos cambian con el tiempo, se suma al desafío de la escasez de la clase positiva en periodos recientes y limita su potencial actual para ser utilizado como un método predictivo directo con fiabilidad sostenida a largo plazo.

A pesar de esta limitación para la predicción directa a futuro, el planteamiento de la aplicación del modelo y la naturaleza espacio-temporal de nuestros datos abren una posibilidad muy valiosa. En lugar de descartar el modelo por la deriva, se propone su uso como una herramienta analítica para comparar las tendencias recientes observadas en los valores de severidad (por ejemplo, entre diferentes 'estados' o zonas geográficas) con las predicciones que el modelo habría generado. Este enfoque comparativo podría ser fundamental para identificar factores dinámicos o emergentes que estén afectando la severidad de los accidentes en periodos específicos o regiones particulares. De esta manera, el ST-GPC serviría no solo como un predictor, sino como un instrumento para generar hipótesis y guiar investigaciones más profundas sobre las causas subyacentes de la severidad de los accidentes.”

2.3.2. *Modelo de Regresión: Procesos Gaussianos Espacio-Temporales (ST-GPR)*

Para abordar la predicción robusta de recuentos de accidentes espacio-temporales, se ha implementado un modelo de Regresión por Procesos Gaussianos Espacio-Temporales (ST-GPR) de múltiples etapas, inspirado en metodologías avanzadas de modelado de series de tiempo Tymeson (2019). Este enfoque descompone la variabilidad de la variable objetivo en componentes explicables por covariables y patrones espacio-temporales, proporcionando además una medida de incertidumbre.

La formulación matemática general del modelo implementado es:

$$Y(s, t) = \beta_0 + \beta_1 \cdot T(t) + \sum_{j=1}^P \beta_j \cdot X_j(s, t) + \sum_{k=1}^M \gamma_k \cdot I_k(s) + \mathcal{GP}_s(t) + \epsilon'(s, t)$$

Donde $Y(s, t)$ es la variable objetivo transformada, $T(t)$ es el identificador temporal, $X_j(s, t)$ son las covariables, $I_k(s)$ son variables dummy para los efectos fijos espaciales, β y γ son los coeficientes de regresión, $\mathcal{GP}_s(t)$ es la parte modelada por el Proceso Gaussiano específico para cada ubicación s sobre el tiempo t , y $\epsilon'(s, t)$ son los residuales no modelados.

Fundamentación y Etapas del Modelo ST-GPR

El modelo ST-GPR se articula en las siguientes etapas secuenciales:

1. Transformación de la Variable Objetivo

La variable original de conteo de accidentes, $Y_{orig}(s, t)$, se transforma utilizando la función log-uno-más-x para manejar su asimetría y la presencia de ceros, haciéndola más adecuada para el modelado.

$$Y(s, t) = \log(1 + Y_{orig}(s, t))$$

2. Etapa 1: Modelado de la Tendencia (Regresión)

Una regresión lineal de mínimos cuadrados ordinarios (OLS) se emplea para capturar la tendencia principal de la variable transformada $Y(s, t)$. Esta regresión incorpora efectos temporales ($T(t)$), covariables ($X_j(s, t)$) y efectos fijos espaciales ($I_k(s)$). Las predicciones de esta etapa, $\hat{Y}_{reg}(s, t)$, representan la estimación de la tendencia.

$$\hat{Y}_{reg}(s, t) = \hat{\beta}_0 + \hat{\beta}_1 \cdot T(t) + \sum_{j=1}^P \hat{\beta}_j \cdot X_j(s, t) + \sum_{k=1}^M \hat{\gamma}_k \cdot I_k(s)$$

3. Etapa 2: Suavizado Temporal de Residuales

Los residuales de la Etapa 1, $R(s, t) = Y(s, t) - \hat{Y}_{reg}(s, t)$, son sometidos a un suavizado temporal mediante un filtro Gaussiano para cada ubicación s . Esto ayuda a aislar la autocorrelación temporal local. La función media para la siguiente etapa, el Proceso Gaussiano ($\mu_{GP}(s, t)$), se construye combinando las predicciones de la regresión con estos residuales suavizados:

$$\mu_{GP}(s, t) = \hat{Y}_{reg}(s, t) + \text{GaussianFilter}(R_s(t), \sigma_{smooth})$$

4. Etapa 3: Proceso Gaussiano (GP) y Modelado de la Incertidumbre

Para cada ubicación espacial s , un Proceso Gaussiano se ajusta sobre el tiempo, utilizando $\mu_{GP}(s, t)$ como su función media. Este GP modela la variabilidad residual autocorrelacionada no explicada por las etapas anteriores. La formulación es:

$$Y(s, t) \sim \mathcal{GP}(\mu_{GP}(s, t), k(t, t') + \sigma_n^2 \delta_{t, t'})$$

Donde $k(t, t')$ es la función de covarianza (kernel Mátern 5/2 o RBF) que captura la similitud temporal, y $\sigma_n^2 \delta_{t, t'}$ representa la varianza de ruido. La varianza de ruido incluye la varianza intrínseca de los datos y una varianza de no muestreo (NSV) específica por zona, que se estima junto con una amplitud global para la varianza del kernel. El modelo estima las predicciones transformadas, $\hat{Y}_{GP}(s, t)$, y sus incertidumbres.

5. Post-procesamiento e Inversión de la Transformación

Finalmente, las predicciones del GP se transforman de vuelta a la escala original de conteo de accidentes:

$$\hat{Y}_{orig}(s, t) = \exp(\hat{Y}_{GP}(s, t)) - 1$$

Este enfoque de múltiples etapas permite una predicción precisa y una cuantificación robusta de la incertidumbre en datos espacio-temporales de conteo.




Figure 40: Predicciones del Modelo ST-GPR para una Ubicación Geográfica Específica.

Resultados

La Figura 40 ilustra el rendimiento del modelo ST-GPR al pronosticar los conteos de accidentes a lo largo del tiempo para una ubicación geográfica específica. La línea negra representa los conteos de accidentes reales, mientras que la línea azul indica las predicciones del modelo. El área sombreada en azul claro denota la banda de incertidumbre del 95%, proporcionando un rango de confianza para las predicciones. Se observa que el modelo es capaz de capturar la tendencia general de los datos, incluyendo la aparición de picos y valles en el número de accidentes, así como la predicción de valores cercanos a cero cuando no se reportan incidentes. La banda de incertidumbre se ajusta dinámicamente, reflejando una mayor confianza en las predicciones de valores bajos y una mayor dispersión en los valores más altos, lo cual es coherente con la naturaleza de los datos de conteo.

Métrica	RMSE	MAE	MAPE (%)	SMAPE (%)	MASE	R ²
Valor Promedio	0.3787	0.0829	1.2695e+06	32.5617	0.1542	0.9642
Desv. Estándar	0.1325	0.0333	4.4493e+05	11.0197	0.0592	0.0169

Nota: El MAPE se infla debido a la alta proporción de ceros en la variable objetivo.

Table 10: Métricas de Evaluación Promedio del Modelo ST-GPR

La evaluación del modelo de Regresión por Procesos Gaussianos Espacio-Temporales (ST-GPR) se realizó mediante una validación TimeSeriesplit estricta, lo que permite una evaluación robusta de su capacidad de pronóstico sobre datos temporales no vistos. Al comparar el rendimiento del modelo ST-GPR con una serie de modelos de benchmark (KNN, Ridge, Lasso, Random Forest, XGBoost, SVR), se observó una superioridad drástica en las métricas de error absoluto. El ST-GPR alcanzó un RMSE promedio de 0.3787 y un MAE promedio de 0.0829, lo que representa una reducción de error de aproximadamente 10 a 25 veces menor que la de los mejores modelos de benchmark (cuyos RMSE y MAE

Métrica	Ljung-Box p-valor	Jarque-Bera p-valor
Valor Promedio	0.0000	0.0000
Desv. Estándar	N/A	N/A

Nota: Los p-valores se reportan como promedio. Sus desviaciones estándar individuales no son directamente informativas en este contexto.

Table 11: Métricas de Evaluación Promedio del Modelo ST-GPR

se encuentran entre 3.84-6.09 y 2.08-3.53, respectivamente). Este rendimiento superior se extiende al coeficiente de determinación (R^2), con un promedio de 0.9642, aunque se reconoce que este valor puede estar artificialmente inflado debido a la alta proporción de observaciones con cero accidentes en el conjunto de datos. Por lo tanto, para una evaluación más fiable, se prioriza la interpretación de las métricas absolutas (RMSE, MAE) y se complementa con el SMAPE (32.56%) y el MASE (0.1542), siendo este último notablemente inferior a 1.0, lo que indica que el modelo ST-GPR supera significativamente a un pronóstico ingenuo.

A pesar de la alta precisión predictiva, el análisis de los residuales del modelo ST-GPR reveló que estos aún presentan autocorrelación significativa (p-valor de Ljung-Box promedio de 0.0000) y no siguen una distribución normal (p-valor de Jarque-Bera promedio de 0.0000). Esta característica es compartida con los modelos de benchmark, cuyos residuales también exhiben p-valores de 0.0 para ambas pruebas, lo que sugiere que ninguno de los modelos logra capturar completamente la estructura temporal y la distribución de los errores.

Para futuras mejoras del modelo, se plantea la integración de técnicas de modelado que soporten intrínsecamente la alta proporción de ceros presentes en los datos de conteo de accidentes. Esto podría lograrse mediante la implementación de modelos Zero-Inflated (como Poisson o Binomial Negativa) o Hurdle Models en la etapa de regresión inicial (Etapa 1), antes de pasar a la Etapa 3 del Proceso Gaussiano. Estos modelos están diseñados para distinguir entre ceros "estructurales" (cuando un evento no puede ocurrir) y ceros "por azar" (cuando un evento podría haber ocurrido pero no lo hizo), lo que permitiría un modelado más preciso de la distribución de los conteos de accidentes y podría refinar la naturaleza de los residuales subsiguientes que son modelados por el GP.

3. Códigos Fuente de los Modelos

Los códigos fuente utilizados para el desarrollo y la evaluación de los modelos presentados en este documento se encuentran disponibles en el siguiente Jupyter Book:

<https://Ansemon.github.io/ml3/>

References

- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1):5–32.
- Chen, T. and Guestrin, C. (2016). Xgboost: A scalable tree boosting system. *arXiv preprint arXiv:1603.02754*. Submitted on 9 Mar 2016 (v1), last revised 10 Jun 2016 (this version, v3).
- Cortes, C. and Vapnik, V. (1995). Support-vector networks. *Machine learning*, 20(3):273–297.
- Hastie, T., Tibshirani, R., and Friedman, J. (2009). *The Elements of Statistical Learning*. Springer.
- Quinlan, J. R. (1986). Induction of decision trees. *Machine Learning*, 1(1):81–106.
- Tymeson, H. (2019). Adapting spatiotemporal gaussian process regression for multinomial data. Master of public health, University of Washington.